

linear2D_system_KalmanGain_comparison_KalmanNet_EKF

October 15, 2025

```
[16]: import sys
import os

notebook_path = os.getcwd()
parent_dir = os.path.dirname(notebook_path)
project_root = os.path.dirname(parent_dir)
if project_root not in sys.path:
    sys.path.insert(0, project_root)
```

```
[17]: import torch
import torch.nn as nn
from torch.utils.data import DataLoader, TensorDataset
import matplotlib.pyplot as plt
from copy import deepcopy
```

```
[18]: import state_NN_models
import Filters
import utils
import Systems
from utils import losses, trainer, utils
from torch.utils.data import TensorDataset, DataLoader, random_split
from state_NN_models.StateBayesianKalmanNet import StateBayesianKalmanNet
from state_NN_models.StateKalmanNet import StateKalmanNet
from state_NN_models.StateKalmanNetWithKnownR import StateKalmanNetWithKnownR
```

```
[19]: device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print(f"Používané zařízení: {device}")
```

Používané zařízení: cuda

```
[20]: state_dim_2d = 2
obs_dim_2d = 2

F_base_2d = torch.tensor([[1.0, 1.0],
                           [0.0, 1.0]])

svd_F = torch.linalg.svd(F_base_2d)
F_true_2d = F_base_2d / svd_F.S[0]
```

```

H_true_2d = torch.eye(obs_dim_2d)

Q_true_2d = torch.eye(state_dim_2d) * 0.5 # Šum procesu
R_true_2d = torch.eye(obs_dim_2d) * 0.1 # Šum měření

# Počáteční podmínky
Ex0_true_2d = torch.tensor([[1.0], [0.0]])
P0_true_2d = torch.eye(state_dim_2d) * 1.5
F_model_2d = F_true_2d
H_model_2d = H_true_2d
Q_model_2d = torch.eye(state_dim_2d) * 0.1
R_model_2d = R_true_2d*5.0
Ex0_model_2d = torch.tensor([[0.5], [0.5]])
P0_model_2d = torch.eye(state_dim_2d) * 1.0

print("\nInicializuji 2D Linear_Canonical systém (replikace autorů)...")
sys_true = Systems.DynamicSystem(
    state_dim=state_dim_2d, obs_dim=obs_dim_2d,
    Ex0=Ex0_true_2d, P0=P0_true_2d,
    Q=Q_true_2d, R=R_true_2d,
    F=F_true_2d, H=H_true_2d,
    device=device
)
sys_model = Systems.DynamicSystem(
    state_dim=state_dim_2d, obs_dim=obs_dim_2d,
    Ex0=Ex0_model_2d, P0=P0_model_2d,
    Q=Q_model_2d, R=R_model_2d,
    F=F_model_2d, H=H_model_2d,
    device=device
)
print("... 2D systém inicializován.")

```

Inicializuji 2D Linear_Canonical systém (replikace autorů)...
 ... 2D systém inicializován.

```

[21]: TRAIN_SEQ_LEN = 10      # Krátké sekvence pro stabilní trénink (TBPTT)
      VALID_SEQ_LEN = 20     # Stejná délka pro konzistentní validaci
      TEST_SEQ_LEN = 100     # Dlouhé sekvence pro testování generalizace

      NUM_TRAIN_TRAJ = 500   # Hodně trénovacích příkladů
      NUM_VALID_TRAJ = 200   # Dostatek pro spolehlivou validaci
      NUM_TEST_TRAJ = 100    # Pro robustní vyhodnocení

      BATCH_SIZE = 8         # Dobrý kompromis

```

```

x_train, y_train = utils.generate_data(sys_true,
    ↪ num_trajectories=NUM_TRAIN_TRAJ, seq_len=TRAIN_SEQ_LEN)
x_val, y_val = utils.generate_data(sys_true, num_trajectories=NUM_VALID_TRAJ,
    ↪ seq_len=VALID_SEQ_LEN)
x_test, y_test = utils.generate_data(sys_true, num_trajectories=1,
    ↪ seq_len=TEST_SEQ_LEN)

train_dataset = TensorDataset(x_train, y_train)
val_dataset = TensorDataset(x_val, y_val)

train_loader = DataLoader(train_dataset, batch_size=BATCH_SIZE, shuffle=True)
val_loader = DataLoader(val_dataset, batch_size=BATCH_SIZE, shuffle=False)

```

```

[22]: import torch
import torch.nn as nn
from torch.utils.data import TensorDataset, DataLoader
import numpy as np
import os
import random
import csv
from datetime import datetime
import pandas as pd
from copy import deepcopy

model_config = {
    "hidden_size_multiplier": 11,
    "output_layer_multiplier": 4,
    "num_gru_layers": 1,
    "init_min_dropout": 0.6,
    "init_max_dropout": 0.8
}

train_config = {
    "total_train_iter": 1400,
    "learning_rate": 1e-4,
    "clip_grad": 10.0,
    "J_samples": 20,
    "validation_period": 20,
    "logging_period": 20,
    "warmup_iterations": 100 # Trénuj prvních 400 iterací jen na MSE
}

#
↪ =====
# KROK 3: SPUŠTĚNÍ JEDNOHO TRÉNINKOVÉHO BĚHU
#
↪ =====

```

```

print("="*80)
print("Spouštím jeden plnohodnotný tréninkový běh...")
print(f"Parametry modelu: {model_config}")
print(f"Parametry tréninku: {train_config}")
print("="*80)

# Nastavení seedu pro reprodukovatelnost tohoto běhu
torch.manual_seed(42)
np.random.seed(42)
random.seed(42)

# Vytvoření modelu
state_bkn_knet = StateBayesianKalmanNet(
    sys_model,
    device=device,
    **model_config
).to(device)

# Spuštění tréninku
# Používáme `run_training_session`, která vrací slovník s výsledky
results = trainer.
    ↪ training_session_trajectory_with_gaussian_nll_training_fcn(model=state_bkn_knet,
        train_loader=train_loader,
        val_loader=val_loader,
        device=device,
        **train_config
    )

# `run_training_session` automaticky načte nejlepší model zpět,
# takže `state_bkn_knet` nyní obsahuje váhy nejlepšího modelu.
trained_model = results['final_model']

print("\n" + "="*80)
print("TRÉNINK DOKONČEN - FINÁLNÍ VÝSLEDKY Z NEJLEPŠÍHO MODELU")
print("="*80)
print(f"Nejlepší model byl nalezen v iteraci: {results['best_iter']}")
# --- Změněné klíče, aby odpovídaly return statementu ---
print(f"Nejlepší dosažený validační ANEES: {results['best_val_anees']:.4f}")
print("--- Metriky odpovídající tomuto nejlepšímu modelu ---")
print(f"    MSE na validační sadě: {results['best_val_mse']:.4f}")
print(f"    NLL na validační sadě: {results['best_val_nll']:.4f}")
print("="*80)

# Nyní můžeš s `trained_model` pokračovat, například ho vyhodnotit na testovací
    ↪ sadě.

```

```

=====
Spouštím jeden plnohodnotný tréninkový běh...
Parametry modelu: {'hidden_size_multiplier': 11, 'output_layer_multiplier': 4,
'num_gru_layers': 1, 'init_min_dropout': 0.6, 'init_max_dropout': 0.8}
Parametry tréninku: {'total_train_iter': 1400, 'learning_rate': 0.0001,
'clip_grad': 10.0, 'J_samples': 20, 'validation_period': 20, 'logging_period':
20, 'warmup_iterations': 100}
=====
--- Iteration [20/1400] ---
- Total Loss: 0.3938
- NLL: 0.0000
- Reg: 0.0052
- p1=0.779, p2=0.631

--- Validace v iteraci 20 ---
Průměrný MSE: 0.4157, Průměrný ANEES: 20.5639
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [40/1400] ---
- Total Loss: 0.2891
- NLL: 0.0000
- Reg: 0.0052
- p1=0.779, p2=0.631

--- Validace v iteraci 40 ---
Průměrný MSE: 0.2988, Průměrný ANEES: 15.8231
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [60/1400] ---
- Total Loss: 0.2532
- NLL: 0.0000
- Reg: 0.0052
- p1=0.779, p2=0.631

--- Validace v iteraci 60 ---
Průměrný MSE: 0.2239, Průměrný ANEES: 12.3784
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [80/1400] ---
- Total Loss: 0.1917
- NLL: 0.0000
- Reg: 0.0052
- p1=0.779, p2=0.631

--- Validace v iteraci 80 ---
Průměrný MSE: 0.1745, Průměrný ANEES: 10.6512
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

```

```

--- Iteration [100/1400] ---
- Total Loss: 0.1795
- NLL: 0.0000
- Reg: 0.0052
- p1=0.778, p2=0.631

--- Validace v iteraci 100 ---
Průměrný MSE: 0.1438, Průměrný ANEES: 9.4824
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [120/1400] ---
- Total Loss: 2.7355
- NLL: 2.7303
- Reg: 0.0052
- p1=0.778, p2=0.632

--- Validace v iteraci 120 ---
Průměrný MSE: 0.1176, Průměrný ANEES: 7.0637
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [140/1400] ---
- Total Loss: 0.9909
- NLL: 0.9857
- Reg: 0.0052
- p1=0.778, p2=0.633

--- Validace v iteraci 140 ---
Průměrný MSE: 0.1050, Průměrný ANEES: 6.0032
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [160/1400] ---
- Total Loss: 0.8124
- NLL: 0.8072
- Reg: 0.0052
- p1=0.778, p2=0.633

--- Validace v iteraci 160 ---
Průměrný MSE: 0.1031, Průměrný ANEES: 5.3546
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [180/1400] ---
- Total Loss: 3.4277
- NLL: 3.4225
- Reg: 0.0052
- p1=0.778, p2=0.634

--- Validace v iteraci 180 ---
Průměrný MSE: 0.0994, Průměrný ANEES: 4.7711

```

```

>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [200/1400] ---
- Total Loss: 0.9471
- NLL: 0.9418
- Reg: 0.0052
- p1=0.778, p2=0.634

--- Validace v iteraci 200 ---
Průměrný MSE: 0.0996, Průměrný ANEES: 4.5528
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [220/1400] ---
- Total Loss: 0.9319
- NLL: 0.9266
- Reg: 0.0052
- p1=0.778, p2=0.634

--- Validace v iteraci 220 ---
Průměrný MSE: 0.1008, Průměrný ANEES: 4.2544
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [240/1400] ---
- Total Loss: 1.5276
- NLL: 1.5223
- Reg: 0.0052
- p1=0.778, p2=0.635

--- Validace v iteraci 240 ---
Průměrný MSE: 0.0993, Průměrný ANEES: 4.3190
-----
--- Iteration [260/1400] ---
- Total Loss: 0.8343
- NLL: 0.8290
- Reg: 0.0052
- p1=0.778, p2=0.635

--- Validace v iteraci 260 ---
Průměrný MSE: 0.0998, Průměrný ANEES: 3.9885
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [280/1400] ---
- Total Loss: 0.8986
- NLL: 0.8934
- Reg: 0.0052
- p1=0.778, p2=0.635

--- Validace v iteraci 280 ---

```

```

Průměrný MSE: 0.0985, Průměrný ANEES: 3.7776
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [300/1400] ---
- Total Loss: 1.9953
- NLL: 1.9901
- Reg: 0.0052
- p1=0.778, p2=0.635

--- Validace v iteraci 300 ---
Průměrný MSE: 0.0982, Průměrný ANEES: 3.7539
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [320/1400] ---
- Total Loss: 1.2204
- NLL: 1.2152
- Reg: 0.0052
- p1=0.778, p2=0.635

--- Validace v iteraci 320 ---
Průměrný MSE: 0.0993, Průměrný ANEES: 3.7666
-----
--- Iteration [340/1400] ---
- Total Loss: 1.3367
- NLL: 1.3315
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 340 ---
Průměrný MSE: 0.0978, Průměrný ANEES: 3.7376
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [360/1400] ---
- Total Loss: 1.0287
- NLL: 1.0235
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 360 ---
Průměrný MSE: 0.1013, Průměrný ANEES: 3.6215
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [380/1400] ---
- Total Loss: 0.9877
- NLL: 0.9825
- Reg: 0.0052
- p1=0.777, p2=0.636

```



```

--- Validace v iteraci 380 ---
Průměrný MSE: 0.0991, Průměrný ANEES: 3.5126
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [400/1400] ---
- Total Loss: 0.7006
- NLL: 0.6953
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 400 ---
Průměrný MSE: 0.0992, Průměrný ANEES: 3.3764
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [420/1400] ---
- Total Loss: 0.9592
- NLL: 0.9539
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 420 ---
Průměrný MSE: 0.1002, Průměrný ANEES: 3.3538
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [440/1400] ---
- Total Loss: 0.9960
- NLL: 0.9907
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 440 ---
Průměrný MSE: 0.0984, Průměrný ANEES: 3.3342
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [460/1400] ---
- Total Loss: 0.7803
- NLL: 0.7751
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 460 ---
Průměrný MSE: 0.0977, Průměrný ANEES: 3.3174
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [480/1400] ---
- Total Loss: 1.3973
- NLL: 1.3921
- Reg: 0.0052

```

```

- p1=0.777, p2=0.636

--- Validace v iteraci 480 ---
Průměrný MSE: 0.0999, Průměrný ANEES: 3.2204
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [500/1400] ---
- Total Loss: 0.8170
- NLL: 0.8117
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 500 ---
Průměrný MSE: 0.1007, Průměrný ANEES: 3.3356
-----

--- Iteration [520/1400] ---
- Total Loss: 1.4367
- NLL: 1.4314
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 520 ---
Průměrný MSE: 0.0990, Průměrný ANEES: 3.2033
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [540/1400] ---
- Total Loss: 0.5069
- NLL: 0.5017
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 540 ---
Průměrný MSE: 0.0988, Průměrný ANEES: 3.1340
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [560/1400] ---
- Total Loss: 0.7294
- NLL: 0.7242
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 560 ---
Průměrný MSE: 0.0981, Průměrný ANEES: 3.1088
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [580/1400] ---
- Total Loss: 0.8701
- NLL: 0.8648

```

```

- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 580 ---
Průměrný MSE: 0.1011, Průměrný ANEES: 3.2674
-----

--- Iteration [600/1400] ---
- Total Loss: 1.0745
- NLL: 1.0693
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 600 ---
Průměrný MSE: 0.0985, Průměrný ANEES: 3.1355
-----

--- Iteration [620/1400] ---
- Total Loss: 1.0930
- NLL: 1.0878
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 620 ---
Průměrný MSE: 0.0992, Průměrný ANEES: 3.0822
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [640/1400] ---
- Total Loss: 1.0006
- NLL: 0.9954
- Reg: 0.0052
- p1=0.777, p2=0.636

--- Validace v iteraci 640 ---
Průměrný MSE: 0.0998, Průměrný ANEES: 3.0333
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [660/1400] ---
- Total Loss: 0.7448
- NLL: 0.7395
- Reg: 0.0052
- p1=0.777, p2=0.637

--- Validace v iteraci 660 ---
Průměrný MSE: 0.1003, Průměrný ANEES: 3.0877
-----

--- Iteration [680/1400] ---
- Total Loss: 1.9718
- NLL: 1.9666
- Reg: 0.0052

```

```

- p1=0.777, p2=0.637

--- Validace v iteraci 680 ---
Průměrný MSE: 0.0995, Průměrný ANEES: 3.0191
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [700/1400] ---
- Total Loss: 1.4424
- NLL: 1.4371
- Reg: 0.0052
- p1=0.777, p2=0.637

--- Validace v iteraci 700 ---
Průměrný MSE: 0.1001, Průměrný ANEES: 3.0040
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [720/1400] ---
- Total Loss: 1.0972
- NLL: 1.0920
- Reg: 0.0052
- p1=0.777, p2=0.637

--- Validace v iteraci 720 ---
Průměrný MSE: 0.1023, Průměrný ANEES: 2.9378
>>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----

--- Iteration [740/1400] ---
- Total Loss: 0.9337
- NLL: 0.9285
- Reg: 0.0052
- p1=0.777, p2=0.637

--- Validace v iteraci 740 ---
Průměrný MSE: 0.0982, Průměrný ANEES: 3.0605
-----

--- Iteration [760/1400] ---
- Total Loss: 0.9409
- NLL: 0.9357
- Reg: 0.0052
- p1=0.777, p2=0.637

--- Validace v iteraci 760 ---
Průměrný MSE: 0.1021, Průměrný ANEES: 3.0540
-----

--- Iteration [780/1400] ---
- Total Loss: 1.0644
- NLL: 1.0592
- Reg: 0.0052

```

```

- p1=0.777, p2=0.637

--- Validace v iteraci 780 ---
  Průměrný MSE: 0.1012, Průměrný ANEES: 2.9992
-----
--- Iteration [800/1400] ---
  - Total Loss: 1.1677
  - NLL: 1.1625
  - Reg: 0.0052
  - p1=0.776, p2=0.637

--- Validace v iteraci 800 ---
  Průměrný MSE: 0.1018, Průměrný ANEES: 3.1911
-----
--- Iteration [820/1400] ---
  - Total Loss: 0.7175
  - NLL: 0.7123
  - Reg: 0.0052
  - p1=0.776, p2=0.637

--- Validace v iteraci 820 ---
  Průměrný MSE: 0.1012, Průměrný ANEES: 3.0237
-----
--- Iteration [840/1400] ---
  - Total Loss: 1.1283
  - NLL: 1.1231
  - Reg: 0.0052
  - p1=0.776, p2=0.637

--- Validace v iteraci 840 ---
  Průměrný MSE: 0.0994, Průměrný ANEES: 2.9203
  >>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [860/1400] ---
  - Total Loss: 1.1623
  - NLL: 1.1571
  - Reg: 0.0052
  - p1=0.776, p2=0.637

--- Validace v iteraci 860 ---
  Průměrný MSE: 0.0996, Průměrný ANEES: 2.9366
-----
--- Iteration [880/1400] ---
  - Total Loss: 1.1029
  - NLL: 1.0977
  - Reg: 0.0052
  - p1=0.776, p2=0.637

```

```

--- Validace v iteraci 880 ---
    Průměrný MSE: 0.0990, Průměrný ANEES: 3.0545
-----
--- Iteration [900/1400] ---
    - Total Loss: 1.0065
    - NLL: 1.0013
    - Reg: 0.0052
    - p1=0.776, p2=0.637

--- Validace v iteraci 900 ---
    Průměrný MSE: 0.0987, Průměrný ANEES: 2.8559
    >>> Nové nejlepší VALIDAČNÍ ANEES! Ukládám model. <<<
-----
--- Iteration [920/1400] ---
    - Total Loss: 0.8572
    - NLL: 0.8520
    - Reg: 0.0052
    - p1=0.776, p2=0.637

--- Validace v iteraci 920 ---
    Průměrný MSE: 0.1011, Průměrný ANEES: 3.1350
-----
--- Iteration [940/1400] ---
    - Total Loss: 0.9440
    - NLL: 0.9388
    - Reg: 0.0052
    - p1=0.776, p2=0.637

--- Validace v iteraci 940 ---
    Průměrný MSE: 0.1003, Průměrný ANEES: 2.9745
-----
--- Iteration [960/1400] ---
    - Total Loss: 1.6074
    - NLL: 1.6022
    - Reg: 0.0052
    - p1=0.776, p2=0.637

--- Validace v iteraci 960 ---
    Průměrný MSE: 0.1001, Průměrný ANEES: 3.0421
-----
--- Iteration [980/1400] ---
    - Total Loss: 1.0113
    - NLL: 1.0061
    - Reg: 0.0052
    - p1=0.776, p2=0.637

--- Validace v iteraci 980 ---
    Průměrný MSE: 0.0997, Průměrný ANEES: 2.9411

```

```

-----
--- Iteration [1000/1400] ---
- Total Loss: 0.7549
- NLL: 0.7497
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1000 ---
Průměrný MSE: 0.1004, Průměrný ANEES: 2.9160
-----

--- Iteration [1020/1400] ---
- Total Loss: 0.9128
- NLL: 0.9076
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1020 ---
Průměrný MSE: 0.0986, Průměrný ANEES: 2.9377
-----

--- Iteration [1040/1400] ---
- Total Loss: 1.1129
- NLL: 1.1077
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1040 ---
Průměrný MSE: 0.0997, Průměrný ANEES: 3.0916
-----

--- Iteration [1060/1400] ---
- Total Loss: 0.7235
- NLL: 0.7183
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1060 ---
Průměrný MSE: 0.0969, Průměrný ANEES: 2.8713
-----

--- Iteration [1080/1400] ---
- Total Loss: 0.6467
- NLL: 0.6415
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1080 ---
Průměrný MSE: 0.1001, Průměrný ANEES: 3.0285
-----

--- Iteration [1100/1400] ---
- Total Loss: 1.2880

```

```

- NLL: 1.2828
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1100 ---
Průměrný MSE: 0.0991, Průměrný ANEES: 3.1112
-----

--- Iteration [1120/1400] ---
- Total Loss: 1.6712
- NLL: 1.6660
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1120 ---
Průměrný MSE: 0.1014, Průměrný ANEES: 3.0215
-----

--- Iteration [1140/1400] ---
- Total Loss: 1.4034
- NLL: 1.3982
- Reg: 0.0052
- p1=0.776, p2=0.637

--- Validace v iteraci 1140 ---
Průměrný MSE: 0.1004, Průměrný ANEES: 3.1124
-----

--- Iteration [1160/1400] ---
- Total Loss: 0.7315
- NLL: 0.7263
- Reg: 0.0052
- p1=0.775, p2=0.637

--- Validace v iteraci 1160 ---
Průměrný MSE: 0.0997, Průměrný ANEES: 2.9339
-----

--- Iteration [1180/1400] ---
- Total Loss: 0.9457
- NLL: 0.9405
- Reg: 0.0052
- p1=0.775, p2=0.637

--- Validace v iteraci 1180 ---
Průměrný MSE: 0.0993, Průměrný ANEES: 2.8623
-----

--- Iteration [1200/1400] ---
- Total Loss: 1.0716
- NLL: 1.0664
- Reg: 0.0052
- p1=0.775, p2=0.637

```



```

--- Validace v iteraci 1200 ---
    Průměrný MSE: 0.0988, Průměrný ANEES: 3.1505
-----
--- Iteration [1220/1400] ---
    - Total Loss: 0.9482
    - NLL: 0.9430
    - Reg: 0.0052
    - p1=0.775, p2=0.637

--- Validace v iteraci 1220 ---
    Průměrný MSE: 0.0984, Průměrný ANEES: 3.0137
-----
--- Iteration [1240/1400] ---
    - Total Loss: 1.3610
    - NLL: 1.3559
    - Reg: 0.0052
    - p1=0.775, p2=0.637

--- Validace v iteraci 1240 ---
    Průměrný MSE: 0.0994, Průměrný ANEES: 2.9037
-----
--- Iteration [1260/1400] ---
    - Total Loss: 0.9677
    - NLL: 0.9625
    - Reg: 0.0052
    - p1=0.775, p2=0.637

--- Validace v iteraci 1260 ---
    Průměrný MSE: 0.0993, Průměrný ANEES: 2.9754
-----
--- Iteration [1280/1400] ---
    - Total Loss: 0.8408
    - NLL: 0.8356
    - Reg: 0.0052
    - p1=0.775, p2=0.637

--- Validace v iteraci 1280 ---
    Průměrný MSE: 0.0985, Průměrný ANEES: 2.8855
-----
--- Iteration [1300/1400] ---
    - Total Loss: 0.7506
    - NLL: 0.7455
    - Reg: 0.0052
    - p1=0.775, p2=0.637

--- Validace v iteraci 1300 ---
    Průměrný MSE: 0.0997, Průměrný ANEES: 2.9883

```

```

-----
--- Iteration [1320/1400] ---
- Total Loss: 0.7341
- NLL: 0.7289
- Reg: 0.0052
- p1=0.775, p2=0.637

--- Validace v iteraci 1320 ---
Průměrný MSE: 0.1002, Průměrný ANEES: 3.0089
-----
--- Iteration [1340/1400] ---
- Total Loss: 0.8247
- NLL: 0.8195
- Reg: 0.0052
- p1=0.775, p2=0.637

--- Validace v iteraci 1340 ---
Průměrný MSE: 0.0989, Průměrný ANEES: 2.9896
-----
--- Iteration [1360/1400] ---
- Total Loss: 0.8783
- NLL: 0.8732
- Reg: 0.0052
- p1=0.775, p2=0.637

--- Validace v iteraci 1360 ---
Průměrný MSE: 0.0976, Průměrný ANEES: 3.0462
-----
--- Iteration [1380/1400] ---
- Total Loss: 1.5038
- NLL: 1.4986
- Reg: 0.0052
- p1=0.775, p2=0.637

--- Validace v iteraci 1380 ---
Průměrný MSE: 0.0984, Průměrný ANEES: 2.9803
-----
--- Iteration [1400/1400] ---
- Total Loss: 0.9575
- NLL: 0.9524
- Reg: 0.0052
- p1=0.775, p2=0.637

--- Validace v iteraci 1400 ---
Průměrný MSE: 0.0991, Průměrný ANEES: 2.9555
-----

```

Trénování dokončeno.

Načítám nejlepší model z iterace 900 s ANEES 2.8559

```
=====
TRÉNINK DOKONČEN - FINÁLNÍ VÝSLEDKY Z NEJLEPŠÍHO MODELU
=====
```

Nejlepší model byl nalezen v iteraci: 900

Nejlepší dosažený validační ANEES: 2.8559

--- Metriky odpovídající tomuto nejlepšímu modelu ---

MSE na validační sadě: 0.0987

NLL na validační sadě: 0.0000

```
[23]: import torch
import torch.nn as nn
from torch.utils.data import TensorDataset, DataLoader
import numpy as np
import os
import random
import csv
from datetime import datetime
import pandas as pd
from copy import deepcopy
# Nastavení seedu pro reprodukovatelnost tohoto běhu
torch.manual_seed(42)
np.random.seed(42)
random.seed(42)
state_knet = StateKalmanNet(sys_model, device=device,
    ↪hidden_size_multiplier=12).to(device)
trainer.train_state_KalmanNet(
    model=state_knet,
    train_loader=train_loader,
    val_loader=val_loader,
    device=device,
    epochs=100,
    lr=1e-4,
    early_stopping_patience=30
)
```

INFO: Detekováno, že model vrací kovarianci: False

/home/luky/.local/lib/python3.10/site-packages/torch/optim/lr_scheduler.py:28:
UserWarning: The verbose parameter is deprecated. Please use get_last_lr() to
access the learning rate.

warnings.warn("The verbose parameter is deprecated. Please use get_last_lr() "

Epoch [5/100], Train Loss: 0.104677, Val Loss: 0.096906

Epoch [10/100], Train Loss: 0.092308, Val Loss: 0.089804

Epoch [15/100], Train Loss: 0.087464, Val Loss: 0.087904

Epoch [20/100], Train Loss: 0.085180, Val Loss: 0.087043

```
Epoch [25/100], Train Loss: 0.084208, Val Loss: 0.086686
Epoch [30/100], Train Loss: 0.083643, Val Loss: 0.086832
Epoch [35/100], Train Loss: 0.083340, Val Loss: 0.086492
Epoch [40/100], Train Loss: 0.083350, Val Loss: 0.086705
Epoch [45/100], Train Loss: 0.083032, Val Loss: 0.086499
Epoch [50/100], Train Loss: 0.082812, Val Loss: 0.086506
Epoch [55/100], Train Loss: 0.082735, Val Loss: 0.086526
Epoch [60/100], Train Loss: 0.082454, Val Loss: 0.086484
Epoch [65/100], Train Loss: 0.082418, Val Loss: 0.086480
Epoch [70/100], Train Loss: 0.082522, Val Loss: 0.086490
```

Early stopping spuštěno po 73 epochách.

Trénování dokončeno.

Načítám nejlepší model s validační chybou: 0.086462

```
[23]: StateKalmanNet(
      (dnn): DNN_KalmanNet(
        (input_layer): Linear(in_features=4, out_features=96, bias=True)
        (gru): GRU(96, 96)
        (output_layer): Linear(in_features=96, out_features=4, bias=True)
      )
    )
```

```
[24]: import torch
import torch.nn as nn
from torch.utils.data import TensorDataset, DataLoader
import numpy as np
import os
import random
import csv
from datetime import datetime
import pandas as pd
from copy import deepcopy
# Nastavení seedu pro reprodukovatelnost tohoto běhu
torch.manual_seed(42)
np.random.seed(42)
random.seed(42)
state_knetR = StateKalmanNetWithKnownR(sys_model, device=device,
    ↪hidden_size_multiplier=12).to(device)
trainer.train_state_KalmanNet(
    model=state_knetR,
    train_loader=train_loader,
    val_loader=val_loader,
    device=device,
    epochs=100,
    lr=1e-4,
    early_stopping_patience=30
```

```
)
```

```
INFO: Detekováno, že model vrací kovarianci: True
Epoch [5/100], Train Loss: 0.104677, Val Loss: 0.096906, Avg Cov Trace: 0.783992
Epoch [10/100], Train Loss: 0.092308, Val Loss: 0.089804, Avg Cov Trace:
0.806716
Epoch [15/100], Train Loss: 0.087464, Val Loss: 0.087904, Avg Cov Trace:
0.820139
Epoch [20/100], Train Loss: 0.085180, Val Loss: 0.087043, Avg Cov Trace:
0.821469
Epoch [25/100], Train Loss: 0.084208, Val Loss: 0.086686, Avg Cov Trace:
0.825042
Epoch [30/100], Train Loss: 0.083643, Val Loss: 0.086832, Avg Cov Trace:
0.829819
Epoch [35/100], Train Loss: 0.083340, Val Loss: 0.086492, Avg Cov Trace:
0.826626
Epoch [40/100], Train Loss: 0.083350, Val Loss: 0.086705, Avg Cov Trace:
0.830657
Epoch [45/100], Train Loss: 0.083032, Val Loss: 0.086499, Avg Cov Trace:
0.828171
Epoch [50/100], Train Loss: 0.082812, Val Loss: 0.086506, Avg Cov Trace:
0.826141
Epoch [55/100], Train Loss: 0.082735, Val Loss: 0.086526, Avg Cov Trace:
0.832521
Epoch [60/100], Train Loss: 0.082454, Val Loss: 0.086484, Avg Cov Trace:
0.831830
Epoch [65/100], Train Loss: 0.082418, Val Loss: 0.086480, Avg Cov Trace:
0.830997
Epoch [70/100], Train Loss: 0.082522, Val Loss: 0.086490, Avg Cov Trace:
0.830661
```

Early stopping spuštěno po 73 epochách.

Trénování dokončeno.

Načítám nejlepší model s validační chybou: 0.086462

```
[24]: StateKalmanNetWithKnownR(
      (dnn): DNN_KalmanNet(
        (input_layer): Linear(in_features=4, out_features=96, bias=True)
        (gru): GRU(96, 96)
        (output_layer): Linear(in_features=96, out_features=4, bias=True)
      )
    )
```

```
[25]: import torch
import torch.nn.functional as F
import numpy as np
from torch.utils.data import TensorDataset, DataLoader
```

```

# =====
# 0. PŘEDPOKLADY - ZDE PŘIŘAĎTE VAŠE NATRÉNOVANÉ MODELÝ
# =====
# Ujistěte se, že v proměnných níže máte již natrénované a připravené modely.
# Názvy proměnných si upravte podle vašeho kódu, pokud se liší.
try:
    trained_model_bkn = trained_model
    trained_model_classic = state_knet
    trained_model_knetR = state_knetR
    print("INFO: Všechny natrénované modely nalezeny a přiřazeny.")
except NameError:
    print("VAROVÁNÍ: Některé z proměnných `trained_model`, `state_knet`, nebo `state_knetR` nebyly nalezeny.")
    print("      Ujistěte se, že jste nejprve úspěšně dokončili trénink všech modelů.")

# =====
# 1. KONFIGURACE TESTU
# =====
TEST_SEQ_LEN = 300
NUM_TEST_TRAJ = 40
J_SAMPLES_TEST = 25

# =====
# 2. PŘÍPRAVA DAT
# =====
print(f"\nGeneruji {NUM_TEST_TRAJ} testovacích trajektorií o délce {TEST_SEQ_LEN}...")
x_test, y_test = utils.generate_data(sys_true, num_trajectories=NUM_TEST_TRAJ, seq_len=TEST_SEQ_LEN)
test_dataset = TensorDataset(x_test, y_test)
test_loader = DataLoader(test_dataset, batch_size=1, shuffle=False)
print("Generování dat dokončeno.")

# =====
# 3. INICIALIZACE VŠECH FILTRŮ PRO POROVNÁNÍ
# =====
ekf_mismatched = Filters.ExtendedKalmanFilter(sys_model)
ekf_ideal = Filters.ExtendedKalmanFilter(sys_true)
ukf_mismatched = Filters.UnscentedKalmanFilter(sys_model)
ukf_ideal = Filters.UnscentedKalmanFilter(sys_true)
aekf_mismatched = Filters.AdaptiveExtendedKalmanFilter(sys_model, Q_init=sys_model.Q, R_init=sys_model.R, alpha=0.98)
print("Všechny model-based filtry (EKF, UKF, AEKF) inicializovány.")

```

```

# =====
# 4. VYHODNOCOVACÍ SMYČKA
# =====

all_x_true_cpu = []
all_x_hat_bkn_cpu, all_P_hat_bkn_cpu = [], []
all_x_hat_classic_knet_cpu = []
all_x_hat_knetR_cpu, all_P_hat_knetR_cpu = [], []
all_x_hat_ekf_mismatched_cpu, all_P_hat_ekf_mismatched_cpu = [], []
all_x_hat_ekf_ideal_cpu, all_P_hat_ekf_ideal_cpu = [], []
all_x_hat_ukf_mismatched_cpu, all_P_hat_ukf_mismatched_cpu = [], []
all_x_hat_ukf_ideal_cpu, all_P_hat_ukf_ideal_cpu = [], []
all_x_hat_aekf_mismatched_cpu, all_P_hat_aekf_mismatched_cpu = [], []

print(f"\nVyhodnocuji modely na {NUM_TEST_TRAJ} testovacích trajektoriích...")

trained_model_bkn.eval()
trained_model_classic.eval()
trained_model_knetR.eval()

with torch.no_grad():
    for i, (x_true_seq_batch, y_test_seq_batch) in enumerate(test_loader):
        y_test_seq_gpu = y_test_seq_batch.squeeze(0).to(device)
        x_true_seq_gpu = x_true_seq_batch.squeeze(0).to(device)
        initial_state = x_true_seq_gpu[0, :].unsqueeze(0)

        # --- A. Bayesian KalmanNet (Trajectory-wise) ---
        ensemble_trajectories = []
        for j in range(J_SAMPLES_TEST):
            trained_model_bkn.reset(batch_size=1, initial_state=initial_state)
            current_x_hats = []
            for t in range(1, TEST_SEQ_LEN):
                x_filtered_t, _ = trained_model_bkn.step(y_test_seq_gpu[t, :].
↳unsqueeze(0))
                current_x_hats.append(x_filtered_t)
            ensemble_trajectories.append(torch.cat(current_x_hats, dim=0))
        ensemble = torch.stack(ensemble_trajectories, dim=0)
        predictions_bkn = ensemble.mean(dim=0)
        diff = ensemble - predictions_bkn.unsqueeze(0)
        covariances_bkn = (diff.unsqueeze(-1) @ diff.unsqueeze(-2)).mean(dim=0)
        full_x_hat_bkn = torch.cat([initial_state, predictions_bkn], dim=0)
        full_P_hat_bkn = torch.cat([sys_model.P0.unsqueeze(0),
↳covariances_bkn], dim=0)

        # --- B. Klasický StateKalmanNet (pouze MSE) ---
        trained_model_classic.reset(batch_size=1, initial_state=initial_state)

```

```

        classic_knet_preds = []
        for t in range(1, TEST_SEQ_LEN):
            x_filtered_t = trained_model_classic.step(y_test_seq_gpu[t, :].
↳unsqueeze(0))
            classic_knet_preds.append(x_filtered_t)
            full_x_hat_classic_knet = torch.cat([initial_state, torch.
↳cat(classic_knet_preds, dim=0)], dim=0)

        # --- C. StateKalmanNetWithKnownR ---
        trained_model_knetR.reset(batch_size=1, initial_state=initial_state)
        knetR_preds_x, knetR_preds_P = [], []
        for t in range(1, TEST_SEQ_LEN):
            x_filtered_t, P_filtered_t = trained_model_knetR.
↳step(y_test_seq_gpu[t, :].unsqueeze(0))
            knetR_preds_x.append(x_filtered_t)
            knetR_preds_P.append(P_filtered_t)
            full_x_hat_knetR = torch.cat([initial_state, torch.cat(knetR_preds_x,
↳dim=0)], dim=0)
            processed_P_list = []
            for p_tensor in knetR_preds_P:

                while p_tensor.dim() < 2:
                    p_tensor = p_tensor.unsqueeze(-1)

                if p_tensor.dim() > 2 and p_tensor.shape[0] == 1:
                    p_tensor = p_tensor.squeeze(0)
                    processed_P_list.append(p_tensor)

            P_sequence_knetR = torch.stack(processed_P_list, dim=0)

        P0_for_cat = sys_model.P0.clone()
        while P0_for_cat.dim() < P_sequence_knetR.dim():
            P0_for_cat = P0_for_cat.unsqueeze(0)

        full_P_hat_knetR = torch.cat([P0_for_cat, P_sequence_knetR], dim=0)

        # --- D. EKF (nepřesný a ideální) ---
        ekf_m_res = ekf_mismatched.process_sequence(y_test_seq_gpu,
↳Ex0=sys_model.Ex0, P0=sys_model.P0)

        full_x_hat_ekf_m = ekf_m_res['x_filtered'] # Výsledek je již kompletní
↳trajektorie
        full_P_hat_ekf_m = ekf_m_res['P_filtered'] # To samé pro kovarianci

```



```

    ekf_i_res = ekf_ideal.process_sequence(y_test_seq_gpu, Ex0=sys_true.
↳Ex0, P0=sys_true.P0)

    full_x_hat_ekf_i = ekf_i_res['x_filtered']
    full_P_hat_ekf_i = ekf_i_res['P_filtered']

    # --- E. UKF (nepřesný a ideální) ---
    ukf_m_res = ukf_mismatched.process_sequence(y_test_seq_gpu,
↳Ex0=sys_model.Ex0, P0=sys_model.P0)

    full_x_hat_ukf_m = ukf_m_res['x_filtered']
    full_P_hat_ukf_m = ukf_m_res['P_filtered']

    ukf_i_res = ukf_ideal.process_sequence(y_test_seq_gpu, Ex0=sys_true.
↳Ex0, P0=sys_true.P0)

    full_x_hat_ukf_i = ukf_i_res['x_filtered']
    full_P_hat_ukf_i = ukf_i_res['P_filtered']

    # --- G. Uložení všech výsledků na CPU ---
    all_x_true_cpu.append(x_true_seq_gpu.cpu())
    all_x_hat_bkn_cpu.append(full_x_hat_bkn_cpu()); all_P_hat_bkn_cpu.
↳append(full_P_hat_bkn_cpu())
    all_x_hat_classic_knet_cpu.append(full_x_hat_classic_knet_cpu())
    all_x_hat_knetR_cpu.append(full_x_hat_knetR_cpu()); all_P_hat_knetR_cpu.
↳append(full_P_hat_knetR_cpu())
    all_x_hat_ekf_mismatched_cpu.append(full_x_hat_ekf_m_cpu());
↳all_P_hat_ekf_mismatched_cpu.append(full_P_hat_ekf_m_cpu())
    all_x_hat_ekf_ideal_cpu.append(full_x_hat_ekf_i_cpu());
↳all_P_hat_ekf_ideal_cpu.append(full_P_hat_ekf_i_cpu())
    all_x_hat_ukf_mismatched_cpu.append(full_x_hat_ukf_m_cpu());
↳all_P_hat_ukf_mismatched_cpu.append(full_P_hat_ukf_m_cpu())
    all_x_hat_ukf_ideal_cpu.append(full_x_hat_ukf_i_cpu());
↳all_P_hat_ukf_ideal_cpu.append(full_P_hat_ukf_i_cpu())

    print(f"Dokončena trajektorie {i + 1}/{NUM_TEST_TRAJ}...")

# =====
# 5. FINÁLNÍ VÝPOČET A VÝPIS METRIK
# =====
# Seznamy pro sběr metrik
mse_bkn, anees_bkn = [], []; mse_classic_knet = []; mse_knetR, anees_knetR =
↳[], []

```

```

mse_ekf_mis, anees_ekf_mis = [], []; mse_ekf_ideal, anees_ekf_ideal = [], []
mse_ukf_mis, anees_ukf_mis = [], []; mse_ukf_ideal, anees_ukf_ideal = [], []
mse_aekf_mis, anees_aekf_mis = [], []

print("\nPočítám finální metriky pro jednotlivé trajektorie...")

with torch.no_grad():
    for i in range(NUM_TEST_TRAJ):
        x_true = all_x_true_cpu[i]
        def get_metrics(x_hat, P_hat):
            mse = F.mse_loss(x_hat[1:], x_true[1:]).item()
            anees = utils.calculate_anees_vectorized(x_true.unsqueeze(0), x_hat.
↳unsqueeze(0), P_hat.unsqueeze(0))
            return mse, anees

        # Výpočty pro všechny modely
        mse, anees = get_metrics(all_x_hat_bkn_cpu[i], all_P_hat_bkn_cpu[i]);
↳mse_bkn.append(mse); anees_bkn.append(anees)
        mse = F.mse_loss(all_x_hat_classic_knet_cpu[i][1:], x_true[1:]).item();
↳mse_classic_knet.append(mse)
        mse, anees = get_metrics(all_x_hat_knetR_cpu[i],
↳all_P_hat_knetR_cpu[i]); mse_knetR.append(mse); anees_knetR.append(anees)
        mse, anees = get_metrics(all_x_hat_ekf_mismatched_cpu[i],
↳all_P_hat_ekf_mismatched_cpu[i]); mse_ekf_mis.append(mse); anees_ekf_mis.
↳append(anees)
        mse, anees = get_metrics(all_x_hat_ekf_ideal_cpu[i],
↳all_P_hat_ekf_ideal_cpu[i]); mse_ekf_ideal.append(mse); anees_ekf_ideal.
↳append(anees)
        mse, anees = get_metrics(all_x_hat_ukf_mismatched_cpu[i],
↳all_P_hat_ukf_mismatched_cpu[i]); mse_ukf_mis.append(mse); anees_ukf_mis.
↳append(anees)
        mse, anees = get_metrics(all_x_hat_ukf_ideal_cpu[i],
↳all_P_hat_ukf_ideal_cpu[i]); mse_ukf_ideal.append(mse); anees_ukf_ideal.
↳append(anees)

# Funkce pro bezpečné průměrování
def avg(metric_list): return np.mean([m for m in metric_list if not np.
↳isnan(m)])
state_dim_for_nees = all_x_true_cpu[0].shape[1]

# --- Finální výpis tabulky ---
print("\n" + "="*80)
print(f"FINÁLNÍ VÝSLEDKY (průměr přes {NUM_TEST_TRAJ} běhů)")
print("="*80)
print(f"{'Model':<35} | {'Průměrné MSE':<20} | {'Průměrný ANEES':<20}")
print("-" * 80)

```

```

print(f"{'--- Data-Driven Models ---':<35} | {'(nižší je lepší)':<20} |_
↳{'(bližší ' + str(float(state_dim_for_nees)) + ' je lepší)':<20}")
print(f"{'Bayesian KNet (BKN)':<35} | {avg(mse_bkn):<20.4f} | {avg(anees_bkn):
↳<20.4f}")
print(f"{'KNet (pouze MSE)':<35} | {avg(mse_classic_knet):<20.4f} | {'N/A':
↳<20}")
print(f"{'KNet with Known R (KNetR)':<35} | {avg(mse_knetR):<20.4f} |_
↳{avg(anees_knetR):<20.4f}")
print("-" * 80)
print(f"{'--- Model-Based Filters ---':<35} | {'':<20} | {'':<20}")
print(f"{'EKF (Nepřesný model)':<35} | {avg(mse_ekf_mis):<20.4f} |_
↳{avg(anees_ekf_mis):<20.4f}")
print(f"{'UKF (Nepřesný model)':<35} | {avg(mse_ukf_mis):<20.4f} |_
↳{avg(anees_ukf_mis):<20.4f}")
print("-" * 80)
print(f"{'--- Benchmarks ---':<35} | {'':<20} | {'':<20}")
print(f"{'EKF (Ideální model)':<35} | {avg(mse_ekf_ideal):<20.4f} |_
↳{avg(anees_ekf_ideal):<20.4f}")
print(f"{'UKF (Ideální model)':<35} | {avg(mse_ukf_ideal):<20.4f} |_
↳{avg(anees_ukf_ideal):<20.4f}")
print("="*80)

```

INFO: Všechny natrénované modely nalezeny a přiřazeny.

Generuji 40 testovacích trajektorií o délce 300...

Generování dat dokončeno.

Všechny model-based filtry (EKF, UKF, AEKF) inicializovány.

Vyhodnocuji modely na 40 testovacích trajektoriích...

Dokončena trajektorie 1/40...

Dokončena trajektorie 2/40...

Dokončena trajektorie 3/40...

Dokončena trajektorie 4/40...

Dokončena trajektorie 5/40...

Dokončena trajektorie 6/40...

Dokončena trajektorie 7/40...

Dokončena trajektorie 8/40...

Dokončena trajektorie 9/40...

Dokončena trajektorie 10/40...

Dokončena trajektorie 11/40...

Dokončena trajektorie 12/40...

Dokončena trajektorie 13/40...

Dokončena trajektorie 14/40...

Dokončena trajektorie 15/40...

Dokončena trajektorie 16/40...

Dokončena trajektorie 17/40...

Dokončena trajektorie 18/40...

Dokončena trajektorie 19/40...
Dokončena trajektorie 20/40...
Dokončena trajektorie 21/40...
Dokončena trajektorie 22/40...
Dokončena trajektorie 23/40...
Dokončena trajektorie 24/40...
Dokončena trajektorie 25/40...
Dokončena trajektorie 26/40...
Dokončena trajektorie 27/40...
Dokončena trajektorie 28/40...
Dokončena trajektorie 29/40...
Dokončena trajektorie 30/40...
Dokončena trajektorie 31/40...
Dokončena trajektorie 32/40...
Dokončena trajektorie 33/40...
Dokončena trajektorie 34/40...
Dokončena trajektorie 35/40...
Dokončena trajektorie 36/40...
Dokončena trajektorie 37/40...
Dokončena trajektorie 38/40...
Dokončena trajektorie 39/40...
Dokončena trajektorie 40/40...

Počítám finální metriky pro jednotlivé trajektorie...

=====

FINÁLNÍ VÝSLEDKY (průměr přes 40 běhů)

=====

Model	Průměrné MSE	Průměrný ANEES

--- Data-Driven Models ---	(nižší je lepší)	(bližší 2.0 je lepší)
Bayesian KNet (BKN)	0.0952	2.6780
KNet (pouze MSE)	0.0841	N/A
KNet with Known R (KNetR)	0.0841	0.4038

--- Model-Based Filters ---		
EKF (Nepřesný model)	0.3964	6.5003
UKF (Nepřesný model)	0.3964	6.5003

--- Benchmarks ---		
EKF (Ideální model)	0.0834	1.9723
UKF (Ideální model)	0.0834	1.9723
=====		

```
[30]: import matplotlib.pyplot as plt
```

```

TEST_SEQ_LEN = 20
NUM_TEST_TRAJ = 1
J_SAMPLES_TEST = 25

# =====
# 2. PŘÍPRAVA DAT
# =====

print(f"\nGeneruji {NUM_TEST_TRAJ} testovacích trajektorií o délce_
↳ {TEST_SEQ_LEN}...")
x_test, y_test = utils.generate_data(sys_true, num_trajectories=NUM_TEST_TRAJ,
↳ seq_len=TEST_SEQ_LEN)
test_dataset = TensorDataset(x_test, y_test)
test_loader = DataLoader(test_dataset, batch_size=1, shuffle=False)

# KROK 6: POROVNÁNÍ KALMANOVA ZISKU (GAIN)

print("="*80)
print("Provádím analýzu a porovnání Kalmanova zisku...")

# Vybereme jednu trajektorii pro analýzu (např. první z testovací sady)
# Použijeme data, která již byla vygenerována v buňce [6]
x_true_traj = x_test[0].to(device) # Tvar [SEQ_LEN, state_dim]
y_test_traj = y_test[0].to(device) # Tvar [SEQ_LEN, obs_dim]

with torch.no_grad():
    # 1. Získání historie z ideálního EKF
    # Předpokládáme, že `ekf_ideal` byl inicializován v buňce [23]
    # a že jeho metoda `process_sequence` vrací slovník s klíčem 'K_filtered'
    print("Spouštím ideální EKF pro získání referenčního Kalmanova zisku...")
    try:
        ekf_i_res = ekf_ideal.process_sequence(
            y_test_traj,
            Ex0=sys_true.Ex0,
            P0=sys_true.P0
        )
        # Tvar [SEQ_LEN - 1, state_dim, obs_dim]
        ekf_gain_history = ekf_i_res['Kalman_gain'].cpu()
        print("Historie z EKF úspěšně získána.")
    except KeyError:
        print("\nCHYBA: Zdá se, že vaše třída `ExtendedKalmanFilter` nevrací_
↳ klíč 'Kalman_gain'.")
        print("Pro spuštění této buňky je nutné upravit metodu_
↳ `process_sequence` tak, aby vracela i historii Kalmanova zisku.")
        ekf_gain_history = None
    except NameError:

```

```

    print("\nCHYBA: Objekt `ekf_ideal` nebyl nalezen. Ujistěte se, že jste
↳ spustili buňku [23].")
    ekf_gain_history = None

# 2. Získání historie z natrénovaného KNetR
# Předpokládáme, že `trained_model_knetR` je natrénovaný model
print("Spouštím KNetR pro získání jeho Kalmanova zisku...")
try:
    # Resetujeme model na počáteční stav dané trajektorie
    initial_state = x_true_traj[0, :].unsqueeze(0)
    trained_model_knetR.reset(batch_size=1, initial_state=initial_state)

    # Projdeme celou sekvenci a necháme model, aby si uložil historii
    for t in range(1, TEST_SEQ_LEN):
        y_t = y_test_traj[t, :].unsqueeze(0)
        trained_model_knetR.step(y_t)

    # Získáme historii pomocí nové metody
    # Tvar [SEQ_LEN - 1, state_dim, obs_dim]
    knetr_gain_history = trained_model_knetR.get_kalman_gain_history()
    print("Historie z KNetR úspěšně získána.")
except NameError:
    print("\nCHYBA: Objekt `trained_model_knetR` nebyl nalezen. Ujistěte
↳ se, že jste úspěšně natrénovali model StateKalmanNetWithKnownR.")
    knetr_gain_history = None

# 3. Vykreslení grafu pro porovnání
if ekf_gain_history is not None and knetr_gain_history is not None:
    print("Vykresluji graf porovnání...")

    # V našem případě je state_dim=1 a obs_dim=1, takže zisk je skalár
    # Převedeme tenzory na 1D NumPy pole pro snadné vykreslení
    # ekf_gains_to_plot = ekf_gain_history[1:].squeeze().numpy()
    # knetr_gains_to_plot = knetr_gain_history.squeeze().numpy()
    # Z každé matice 2x2 v historii vybereme prvek na pozici (0, 0)
    ekf_gains_to_plot = ekf_gain_history[1:, 0, 0].numpy()
    knetr_gains_to_plot = knetr_gain_history[:, 0, 0].numpy()

    time_steps = range(1, TEST_SEQ_LEN)

    plt.figure(figsize=(14, 7))
    plt.plot(time_steps, knetr_gains_to_plot, label='Kalman Gain z KNetR',
↳ color='r', linewidth=2)
    plt.plot(time_steps, ekf_gains_to_plot, label='Kalman Gain z ideálního
↳ EKF', color='b', linestyle='--', linewidth=2)

```

```

plt.title('Porovnání vývoje Kalmanova zisku v čase', fontsize=16)
plt.xlabel('Časový krok', fontsize=12)
plt.ylabel('Hodnota Kalmanova zisku (Gain)', fontsize=12)
plt.legend(fontsize=12)
plt.grid(True)
plt.xlim(0, TEST_SEQ_LEN)
plt.show()

ekf_gains_to_plot = ekf_gain_history[1:, 1, 1].numpy()
knetr_gains_to_plot = knetr_gain_history[:, 1, 1].numpy()

time_steps = range(1, TEST_SEQ_LEN)

plt.figure(figsize=(14, 7))
plt.plot(time_steps, knetr_gains_to_plot, label='Kalman Gain z KNetR',
color='r', linewidth=2)
plt.plot(time_steps, ekf_gains_to_plot, label='Kalman Gain z ideálního
EKF', color='b', linestyle='--', linewidth=2)

plt.title('Porovnání vývoje Kalmanova zisku v čase', fontsize=16)
plt.xlabel('Časový krok', fontsize=12)
plt.ylabel('Hodnota Kalmanova zisku (Gain)', fontsize=12)
plt.legend(fontsize=12)
plt.grid(True)
plt.xlim(0, TEST_SEQ_LEN)
plt.show()

print("="*80)

```

Generuji 1 testovacích trajektorií o délce 20...

=====

Provádím analýzu a porovnání Kalmanova zisku...



Spouštím ideální EKF pro získání referenčního Kalmanova zisku...

Historie z EKF úspěšně získána.

Spouštím KNetR pro získání jeho Kalmanova zisku...

Historie z KNetR úspěšně získána.

Vykresluji graf porovnání...



=====