

KNET_training_most_consistent

February 4, 2026

```
[1]: from pathlib import Path
from scipy.io import loadmat
import sys
import os

# Robust path finding for data.mat
current_path = Path.cwd()
possible_data_paths = [
    current_path / 'data' / 'data.mat',
    current_path.parent / 'data' / 'data.mat',
    current_path.parent.parent / 'data' / 'data.mat',
    # Fallback absolute path
    Path('/home/luky/skola/KalmanNet-for-state-estimation/data/data.mat')
]

dataset_path = None
for p in possible_data_paths:
    if p.exists():
        dataset_path = p
        break

if dataset_path is None or not dataset_path.exists():
    print("Warning: data.mat not found automatically.")
    dataset_path = Path('data/data.mat')

print(f"Dataset path: {dataset_path}")

# Add project root to sys.path (2 levels up from debug/test)
notebook_dir = os.getcwd()
project_root = os.path.abspath(os.path.join(notebook_dir, '..', '..'))
if project_root not in sys.path:
    sys.path.insert(0, project_root)
print(f"Project root added: {project_root}")

mat_data = loadmat(dataset_path)
print(mat_data.keys())
```

Dataset path: /home/luky/skola/KalmanNet-main/data/data.mat

```
Project root added: /home/luky/skola/KalmanNet-main
dict_keys(['__header__', '__version__', '__globals__', 'hB', 'souradniceGNSS',
'souradniceX', 'souradniceY', 'souradniceZ'])
```

```
[2]: import torch
import matplotlib.pyplot as plt
from utils import trainer
from utils import utils
from Systems import DynamicSystem
import Filters
import torch.nn.functional as F
from torch.utils.data import TensorDataset, DataLoader
import numpy as np
from scipy.io import loadmat
from scipy.interpolate import RegularGridInterpolator
import random
```

```
torch.manual_seed(42)
np.random.seed(42)
random.seed(42)
if torch.cuda.is_available():
    torch.cuda.manual_seed_all(42)

device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
print(f"device: {device}")
```

```
device: cuda
```

```
[3]: mat_data = loadmat(dataset_path)

souradniceX_mapa = mat_data['souradniceX']
souradniceY_mapa = mat_data['souradniceY']
souradniceZ_mapa = mat_data['souradniceZ']
souradniceGNSS = mat_data['souradniceGNSS']
x_axis_unique = souradniceX_mapa[0, :]
y_axis_unique = souradniceY_mapa[:, 0]

print(f"Dimensions of 1D X axis: {x_axis_unique.shape}")
print(f"Dimensions of 1D Y axis: {y_axis_unique.shape}")
print(f"Dimensions of 2D elevation data Z: {souradniceZ_mapa.shape}")

terMap_interpolator = RegularGridInterpolator(
    (y_axis_unique, x_axis_unique),
    souradniceZ_mapa,
    bounds_error=False,
    fill_value=np.nan
)
```

```
def terMap(px, py):
    # Query bilinear interpolation over the terrain map
    points_to_query = np.column_stack((py, px))
    return terMap_interpolator(points_to_query)
```

Dimensions of 1D X axis: (2500,)
 Dimensions of 1D Y axis: (2500,)
 Dimensions of 2D elevation data Z: (2500, 2500)

```
[4]: import torch
from Systems import DynamicSystemTAN

state_dim = 4
obs_dim = 3
dT = 1
q = 1

F = torch.tensor([[1.0, 0.0, dT, 0.0],
                  [0.0, 1.0, 0.0, dT],
                  [0.0, 0.0, 1.0, 0.0],
                  [0.0, 0.0, 0.0, 1.0]])

Q = q* torch.tensor([[dT**3/3, 0.0, dT**2/2, 0.0],
                    [0.0, dT**3/3, 0.0, dT**2/2],
                    [dT**2/2, 0.0, dT, 0.0],
                    [0.0, dT**2/2, 0.0, dT]])

R = torch.tensor([[3.0**2, 0.0, 0.0],
                  [0.0, 1.0**2, 0.0],
                  [0.0, 0.0, 1.0**2]])

initial_velocity_np = souradniceGNSS[:2, 1] - souradniceGNSS[:2, 0]
# initial_velocity_np = torch.from_numpy()
initial_velocity = torch.from_numpy(np.array([0,0]))

initial_position = torch.from_numpy(souradniceGNSS[:2, 0])
x_0 = torch.cat([
    initial_position,
    initial_velocity
]).float()
print(x_0)

P_0 = torch.tensor([[25.0, 0.0, 0.0, 0.0],
                    [0.0, 25.0, 0.0, 0.0],
                    [0.0, 0.0, 0.5, 0.0],
                    [0.0, 0.0, 0.0, 0.5]])

import torch.nn.functional as func
```

```

def h_nl_differentiable(x: torch.Tensor, map_tensor, x_min, x_max, y_min,
    ↪y_max) -> torch.Tensor:
    batch_size = x.shape[0]

    px = x[:, 0]
    py = x[:, 1]

    px_norm = 2.0 * (px - x_min) / (x_max - x_min) - 1.0
    py_norm = 2.0 * (py - y_min) / (y_max - y_min) - 1.0

    sampling_grid = torch.stack((px_norm, py_norm), dim=1).view(batch_size, 1,
    ↪1, 2)

    vyska_terenu_batch = func.grid_sample(
        map_tensor.expand(batch_size, -1, -1, -1),
        sampling_grid,
        mode='bilinear',
        padding_mode='border',
        align_corners=True
    )

    vyska_terenu = vyska_terenu_batch.view(batch_size)

    eps = 1e-12
    vx_w, vy_w = x[:, 2], x[:, 3]
    norm_v_w = torch.sqrt(vx_w**2 + vy_w**2).clamp(min=eps)
    cos_psi = vx_w / norm_v_w
    sin_psi = vy_w / norm_v_w

    vx_b = cos_psi * vx_w - sin_psi * vy_w
    vy_b = sin_psi * vx_w + cos_psi * vy_w

    result = torch.stack([vyska_terenu, vx_b, vy_b], dim=1)

    return result

x_axis_unique = souradniceX_mapa[0, :]
y_axis_unique = souradniceY_mapa[:, 0]
terMap_tensor = torch.from_numpy(souradniceZ_mapa).float().unsqueeze(0).
    ↪unsqueeze(0).to(device)
x_min, x_max = x_axis_unique.min(), x_axis_unique.max()
y_min, y_max = y_axis_unique.min(), y_axis_unique.max()

h_wrapper = lambda x: h_nl_differentiable(
    x,
    map_tensor=terMap_tensor,

```

```

        x_min=x_min,
        x_max=x_max,
        y_min=y_min,
        y_max=y_max
    )

    system_model = DynamicSystemTAN(
        state_dim=state_dim,
        obs_dim=obs_dim,
        Q=Q.float(),
        R=R.float(),
        Ex0=x_0.float(),
        P0=P_0.float(),
        F=F.float(),
        h=h_wrapper,
        x_axis_unique=x_axis_unique,
        y_axis_unique=y_axis_unique,
        device=device
    )

```

```

tensor([1487547.1250, 6395520.5000,      0.0000,      0.0000])
INFO: DynamicSystemTAN inicializován s hranicemi mapy:
  X: [1476611.42, 1489541.47]
  Y: [6384032.63, 6400441.34]

```

```

[5]: import torch
      from torch.utils.data import TensorDataset, DataLoader
      from utils import utils
      import torch
      import numpy as np
      import torch
      import torch.nn as nn
      from torch.utils.data import TensorDataset, DataLoader
      import numpy as np
      import os
      import random
      from copy import deepcopy
      from state_NN_models import TAN
      from utils import trainer

      torch.manual_seed(42)
      np.random.seed(42)
      random.seed(42)

```

```

[6]: import torch
      from torch.utils.data import TensorDataset, DataLoader
      import os

```

```

from utils import trainer # Předpokládám, že toto máš

# === 1. ZJEDNODUŠENÝ DATA MANAGER (BEZ NORMALIZACE) ===
class NavigationDataManager:
    def __init__(self, data_dir):
        """
        Jen držák na cestu k datům. Žádná statistika, žádná normalizace.
        """
        self.data_dir = data_dir

    def get_dataloader(self, seq_len, split='train', shuffle=True,
        ↪ batch_size=32):
        # Sestavení cesty: ./generated_data/len_100/train.pt
        path = os.path.join(self.data_dir, f'len_{seq_len}', f'{split}.pt')

        if not os.path.exists(path):
            raise FileNotFoundError(f" Dataset nenalezen: {path}")

        # Načtení tenzorů
        data = torch.load(path)
        x = data['x'] # Stav [Batch, Seq, DimX]
        y = data['y'] # Měření [Batch, Seq, DimY] - RAW DATA

        # Vytvoření datasetu
        dataset = TensorDataset(x, y)

        return DataLoader(dataset, batch_size=batch_size, shuffle=shuffle)

# === 2. KONFIGURACE CURRICULA ===
DATA_DIR = './generated_data_clean_motion'

# Inicializace manažera (teď je to jen wrapper pro načítání souborů)
data_manager = NavigationDataManager(DATA_DIR)

# Definice fází (zde řídíš, jak se trénink vyvíjí)
curriculum_schedule = [
    # FÁZE 1: Warm-up (Krátké sekvence)
    {
        'phase_id': 1,
        'seq_len': 10,
        'epochs': 500,
        'lr': 1e-3,
        'batch_size': 256
    },
    # FÁZE 2: Stabilizace (Střední délka)
    {

```

```

        'phase_id': 2,
        'seq_len': 100,
        'epochs': 200,
        'lr': 1e-4,
        'batch_size': 128
    },

    # FÁZE 3: Long-term Reality (Plná délka)
    {
        'phase_id': 3,
        'seq_len': 300,
        'epochs': 200,
        'lr': 5e-5,
        'batch_size': 64          # Menší batch kvůli paměti GPU u dlouhých
↪ sekvencí
    }
]

# === 3. NAČÍTÁNÍ DO PAMĚTI (CACHING) ===
print("\n=== NAČÍTÁNÍ RAW DAT Z DISKU (BEZ EXT. NORMALIZACE) ===")
datasets_cache = {}

for phase in curriculum_schedule:
    seq_len = phase['seq_len']
    bs = phase['batch_size']

    print(f" Načítám Fázi {phase['phase_id']}: Seq={seq_len} | Batch={bs} ...")

    try:
        # Použití DataManageru
        train_loader = data_manager.get_dataloader(seq_len=seq_len,
↪ split='train', shuffle=True, batch_size=bs)
        val_loader = data_manager.get_dataloader(seq_len=seq_len, split='val',
↪ shuffle=False, batch_size=bs)

        # Uložení do cache
        datasets_cache[phase['phase_id']] = (train_loader, val_loader)

        # Rychlá kontrola pro jistotu
        x_ex, y_ex = next(iter(train_loader))
        if phase['phase_id'] == 1:
            print(f"    Ukázka RAW dat (y): {y_ex[0, 0, :].tolist()}")
            # Měl bys vidět velká čísla (např. 250.0) a malá (0.2), ne ~0.0

    except FileNotFoundError as e:
        print(f"    CHYBA: {e}")
        # raise e # Odkomentuj, pokud chceš, aby to spadlo při chybě

```

```
print("\n Data připravena. Normalizaci řeší model.")
```

=== NAČÍTÁNÍ RAW DAT Z DISKU (BEZ EXT. NORMALIZACE) ===

Načítám Fázi 1: Seq=10 | Batch=256 ...

Ukázka RAW dat (y): [362.96917724609375, -12.126676559448242,
0.16327548027038574]

Načítám Fázi 2: Seq=100 | Batch=128 ...

Načítám Fázi 3: Seq=300 | Batch=64 ...

Data připravena. Normalizaci řeší model.

Data připravena. Normalizaci řeší model.

```
[8]: # --- A) KONFIGURACE SÍTĚ ---
print("=== INICIALIZACE NOVÉHO MODELU ===")
state_knet2 = TAN.StateKalmanNetTAN(
    system_model=system_model,
    device=device,
    hidden_size_multiplier=10,
    output_layer_multiplier=4,
    num_gru_layers=1,
    gru_hidden_dim_multiplier=6
).to(device)

print(f"Model inicializován. Počet parametrů: {sum(p.numel() for p in
↪state_knet2.parameters() if p.requires_grad)}")

# --- B) SPUŠTĚNÍ TRÉNINKU ---
print("=== SPUŠTĚNÍ TRÉNINKU ===")

for phase in curriculum_schedule:
    phase_id = phase['phase_id']
    seq_len = phase['seq_len']

    print(f"\n--- PHASE {phase_id}: SeqLen {seq_len} ---")

    # 1. Načtení dat
    if phase_id not in datasets_cache:
        raise ValueError("Data nejsou vygenerována! Spust první buňku.")

    train_loader, val_loader = datasets_cache[phase_id]

    # 2. Základní argumenty společné pro obě metody
    common_args = {
        'model': state_knet2,
```



```

        'train_loader': train_loader,
        'val_loader': val_loader,
        'device': device,
        'epochs': phase['epochs'],
        'lr': phase['lr'],
    }

    # 3. Rozvětvení logiky podle délky sekvence
    if seq_len <= 20:
        # === FÁZE 1 & 2: Krátké sekvence (Standardní trénink) ===
        # Zde chceme init_noise pro robustnost startu
        print("-> Using Standard Training (with Init Noise)")
        trainer.train_state_KalmanNetTAN(
            **common_args,
            optimizer_type=torch.optim.AdamW,
            weight_decay=1e-3,
            clip_grad=1.0,
            early_stopping_patience=30
        )
    elif seq_len == 100:
        trainer.train_state_KalmanNetTAN(
            **common_args,
            optimizer_type=torch.optim.AdamW,
            weight_decay=1e-3, # Jemnější weight decay
            clip_grad=1.0,     # Důležité pro stabilitu u delších sekvencí
            early_stopping_patience=30 # Dej mu čas
        )
    else:
        # === FÁZE 3 & 4: Dlouhé sekvence (TBPTT / Sliding Window) ===
        # Zde jsi init_noise odstranil, takže ho nepředáváme
        print("-> Using TBPTT Sliding Window (No Init Noise)")
        trainer.train_state_KalmanNet_sliding_windowTAN(
            **common_args,
            # init_noise argumenty zde vynecháváme!
            weight_decay=1e-4,
            early_stopping_patience=20,
            tbptt_k=2,
            tbptt_w=6,
            optimizer=torch.optim.AdamW,
            clip_grad=1.0
        )
    save_path = f'knet_robust_len{seq_len}.pth'
    torch.save(state_knet2.state_dict(), save_path)
    print(f"Phase {phase_id} completed. Model saved.")

print(" Trénink dokončen.")

```

=== INICIALIZACE NOVÉHO MODELU ===

DEBUG: Layer 'output_final_linear.0' initialized near zero (Start K=0).

Model inicializován. Počet parametrů: 336636

=== SPUŠTĚNÍ TRÉNINKU ===

--- PHASE 1: SeqLen 10 ---

-> Using Standard Training (with Init Noise)

Start training on cuda...

Epoch [1/500] | Train Loss: 476.5820 | Val Loss: 196.3337 -> New Best!

Epoch [2/500] | Train Loss: 177.8750 | Val Loss: 148.3239 -> New Best!

Epoch [3/500] | Train Loss: 126.4690 | Val Loss: 84.6833 -> New Best!

Epoch [4/500] | Train Loss: 63.8577 | Val Loss: 33.1978 -> New Best!

Epoch [5/500] | Train Loss: 26.6732 | Val Loss: 17.7625 | PosMSE: 45.2, VelMSE: 8.1 -> New Best!

Epoch [6/500] | Train Loss: 17.3286 | Val Loss: 15.7249 -> New Best!

Epoch [7/500] | Train Loss: 15.2114 | Val Loss: 14.6847 -> New Best!

Epoch [8/500] | Train Loss: 14.3285 | Val Loss: 14.5488 -> New Best!

Epoch [9/500] | Train Loss: 13.6289 | Val Loss: 14.3594 -> New Best!

Epoch [10/500] | Train Loss: 13.0156 | Val Loss: 14.6162 | PosMSE: 20.7, VelMSE: 5.3

Epoch [13/500] | Train Loss: 11.5852 | Val Loss: 13.5373 -> New Best!

Epoch [15/500] | Train Loss: 10.6790 | Val Loss: 12.9683 | PosMSE: 16.5, VelMSE: 4.8 -> New Best!

Epoch [16/500] | Train Loss: 10.2884 | Val Loss: 12.9310 -> New Best!

Epoch [17/500] | Train Loss: 10.0420 | Val Loss: 12.8504 -> New Best!

Epoch [18/500] | Train Loss: 9.5511 | Val Loss: 12.5462 -> New Best!

Epoch [20/500] | Train Loss: 9.0291 | Val Loss: 12.9866 | PosMSE: 13.5, VelMSE: 4.5

Epoch [25/500] | Train Loss: 7.6769 | Val Loss: 21.6336 | PosMSE: 11.0, VelMSE: 4.4

Epoch [30/500] | Train Loss: 6.6859 | Val Loss: 21.0211 | PosMSE: 9.1, VelMSE: 4.2

Epoch [35/500] | Train Loss: 5.9951 | Val Loss: 21.2410 | PosMSE: 7.8, VelMSE: 4.2

Epoch [40/500] | Train Loss: 5.5621 | Val Loss: 22.5804 | PosMSE: 7.0, VelMSE: 4.1

Epoch [45/500] | Train Loss: 4.9023 | Val Loss: 20.6300 | PosMSE: 5.8, VelMSE: 4.0

Early stopping triggered after 48 epochs.

Training completed.

Loading best model with validation loss: 12.546180

Phase 1 completed. Model saved.

--- PHASE 2: SeqLen 100 ---

Start training on cuda...

Epoch [1/200] | Train Loss: 140.4303 | Val Loss: 133.7433 -> New Best!

Epoch [2/200] | Train Loss: 129.2206 | Val Loss: 129.4049 -> New Best!

Epoch [3/200] | Train Loss: 123.9715 | Val Loss: 129.1813 -> New Best!
 Epoch [4/200] | Train Loss: 123.7668 | Val Loss: 128.0315 -> New Best!
 Epoch [5/200] | Train Loss: 120.1403 | Val Loss: 129.8364 | PosMSE: 236.0,
 VelMSE: 4.3
 Epoch [6/200] | Train Loss: 117.4351 | Val Loss: 126.7113 -> New Best!
 Epoch [10/200] | Train Loss: 109.2590 | Val Loss: 127.8681 | PosMSE: 214.3,
 VelMSE: 4.3
 Epoch [12/200] | Train Loss: 107.5095 | Val Loss: 126.2830 -> New Best!
 Epoch [15/200] | Train Loss: 104.4993 | Val Loss: 126.7387 | PosMSE: 204.7,
 VelMSE: 4.3
 Epoch [16/200] | Train Loss: 102.5341 | Val Loss: 124.7646 -> New Best!
 Epoch [20/200] | Train Loss: 98.2467 | Val Loss: 128.0160 | PosMSE: 192.2,
 VelMSE: 4.3
 Epoch [21/200] | Train Loss: 96.4894 | Val Loss: 124.4825 -> New Best!
 Epoch [25/200] | Train Loss: 95.6488 | Val Loss: 126.9069 | PosMSE: 187.0,
 VelMSE: 4.3
 Epoch [30/200] | Train Loss: 88.9516 | Val Loss: 128.4393 | PosMSE: 173.6,
 VelMSE: 4.3
 Epoch [35/200] | Train Loss: 86.4067 | Val Loss: 127.4814 | PosMSE: 168.5,
 VelMSE: 4.3
 Epoch [40/200] | Train Loss: 82.2153 | Val Loss: 131.8562 | PosMSE: 160.1,
 VelMSE: 4.4
 Epoch [45/200] | Train Loss: 79.6957 | Val Loss: 130.5329 | PosMSE: 155.0,
 VelMSE: 4.4
 Epoch [50/200] | Train Loss: 75.4309 | Val Loss: 132.5446 | PosMSE: 146.5,
 VelMSE: 4.4

Early stopping triggered after 51 epochs.

Training completed.

Loading best model with validation loss: 124.482512

Phase 2 completed. Model saved.

--- PHASE 3: SeqLen 300 ---

-> Using TBPTT Sliding Window (No Init Noise)

INFO: Detected from model attribute that it returns covariance: False

INFO: Starting training with TBPTT(k=2, w=6)

Epoch [1/200] | Train Loss: 705.6535 | Val Loss: 783.1533 -> New Best!

Epoch [2/200] | Train Loss: 4706.7084 | Val Loss: 734.1111 -> New Best!

Epoch [5/200] | Train Loss: 4745.6368 | Val Loss: 660.1076 | Val MSE: 660.11 ->
 New Best!

Epoch [7/200] | Train Loss: 523.2097 | Val Loss: 648.7058 -> New Best!

Epoch [8/200] | Train Loss: 4663.4197 | Val Loss: 574.0026 -> New Best!

Epoch [9/200] | Train Loss: 4708.7633 | Val Loss: 567.1696 -> New Best!

Epoch [10/200] | Train Loss: 518.2530 | Val Loss: 530.8846 | Val MSE: 530.88 ->
 New Best!

Epoch [12/200] | Train Loss: 505.1902 | Val Loss: 516.1132 -> New Best!

Epoch [15/200] | Train Loss: 4715.9606 | Val Loss: 525.0441 | Val MSE: 525.04

Epoch [20/200] | Train Loss: 460.9286 | Val Loss: 567.2135 | Val MSE: 567.21

Epoch [25/200] | Train Loss: 468.2301 | Val Loss: 600.5663 | Val MSE: 600.57
Epoch [30/200] | Train Loss: 437.9915 | Val Loss: 534.9696 | Val MSE: 534.97

Early stopping triggered after 32 epochs.

Training completed.

Loading best model with validation loss: 516.113174

Phase 3 completed. Model saved.

Trénink dokončen.

```
[11]: if True:
        # save model.
        save_path = f'most_consistent_knet.pth'
        torch.save(state_knet2.state_dict(), save_path)
        print(f"Model saved to '{save_path}'.")
```

Model saved to 'most_consistent_knet.pth'.

```
[ ]: # import torch
      # import numpy as np
      # import matplotlib.pyplot as plt

      # # 1. Načteme podezřelý dataset
      # suspicious_path = './generated_data_clean_motion/len_300/val.pt'
      # data = torch.load(suspicious_path)
      # x_gt_all = data['x'].to(device)
      # y_meas_all = data['y'].to(device)

      # print(f" Analyzují dataset: {suspicious_path}")
      # print(f" Počet trajektorií: {len(x_gt_all)}")

      # # 2. Spustíme váš aktuální model (StateKalmanNet) na všech datech
      # state_knet2.eval()
      # losses = []

      # bad_indices = []

      # with torch.no_grad():
      #     for i in range(len(x_gt_all)):
      #         # Příprava jedné trajektorie
      #         x_gt = x_gt_all[i].unsqueeze(0) # [1, Seq, 4]
      #         y_meas = y_meas_all[i].unsqueeze(0) # [1, Seq, 3]

      #         # Reset modelu
      #         state_knet2.reset(batch_size=1, initial_state=x_gt[:, 0, :])

      #         # Inference
      #         preds = []
```

```

#         for t in range(1, x_gt.shape[1]):
#             pred = state_knet2.step(y_meas[:, t, :])
#             preds.append(pred)

#         preds = torch.stack(preds, dim=1) # [1, Seq-1, 4]

#         # Výpočet MSE pro tuto jednu trajektorii
#         loss = torch.nn.functional.mse_loss(preds, x_gt[:, 1:, :]).item()
#         losses.append(loss)

#         # Hledáme extrémy (např. Loss > 500)
#         if loss > 1000:
#             bad_indices.append((i, loss))

# # 3. Výpis výsledků
# losses = np.array(losses)
# print(f"\n Statistika Loss:")
# print(f"    Průměr: {np.mean(losses):.2f}")
# print(f"    Medián: {np.median(losses):.2f}") # Medián nebude ovlivněn
#     ↳outlierem!
# print(f"    Max:      {np.max(losses):.2f}")
# print(f"    Min:      {np.min(losses):.2f}")

# print(f"\n Nalezení viníci (Loss > 1000):")
# for idx, val in bad_indices:
#     print(f"    Index {idx}: Loss = {val:.2f}")

# # 4. Vizualizace nejhoršího případu
# if bad_indices:
#     worst_idx = max(bad_indices, key=lambda item: item[1])[0]
#     print(f"\n Vykresluji nejhorší trajektorii (Index {worst_idx})...")

#     # Znovu spustíme pro vykreslení
#     x_gt = x_gt_all[worst_idx].cpu().numpy()
#     y_meas = y_meas_all[worst_idx].cpu().numpy()

#     # ... (zde by byl kód pro plot, pokud ho chceš) ...
#     # Ale už ta čísla nahoře ti řeknou vše.

```

```

[ ]: # import torch
# import os

# # Cesta k poškozenému souboru
# bad_file = './generated_data_clean_motion/len_300/train.pt'
# backup_file = bad_file + '.bak'

# # 1. Načtení

```

```

# data = torch.load(bad_file)
# x_all = data['x']
# y_all = data['y']

# print(f"Původní počet: {len(x_all)}")

# # 2. Definice indexů k odstranění (z vaší diagnostiky)
# bad_indices = [1887]

# # 3. Vytvoření masky pro zachování dobrých dat
# mask = torch.ones(len(x_all), dtype=torch.bool)
# mask[bad_indices] = False

# # 4. Filtrace
# x_clean = x_all[mask]
# y_clean = y_all[mask]

# print(f"Nový počet: {len(x_clean)}")

# # 5. Uložení (s zálohou)
# if not os.path.exists(backup_file):
#     os.rename(bad_file, backup_file)
#     print(f"Záloha uložena do: {backup_file}")

# torch.save({'x': x_clean, 'y': y_clean}, bad_file)
# print(f"Vyčištěný dataset uložen do: {bad_file}")

```

1 Test na realne trajektorii

```

[10]: import torch
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd # Pro hezkou tabulku
import Filters
from tqdm import tqdm

real_traj_np = souradniceGNSS[:, :].T

real_traj_tensor = torch.from_numpy(real_traj_np).float().to(device)
train_source_tensor = real_traj_tensor[:, :]
# --- POMOCNÁ FUNKCE PRO GENEROVÁNÍ DAT ---
def get_reference_test_set(system, real_traj_tensor, reverse=False):
    # Oříznutí trajektorie (pokud je potřeba)
    # real_traj_tensor = real_traj_tensor[:1050, :]

    device = system.Ex0.device

```

```

# Předpoklad: mat_data je globální proměnná s načteným .mat souborem
hB_np = mat_data['hB']
real_hB_tensor = torch.from_numpy(hB_np).float().to(device).view(-1)

pos_full = real_traj_tensor.clone().to(device)

deltas = pos_full[1:] - pos_full[:-1]
last_vel = deltas[-1:]
velocities = torch.cat([deltas, last_vel], dim=0) # [T, 2]

x_traj_flat = torch.cat([pos_full, velocities], dim=1) # [T, 4]

# Generování měření (s náhodným šumem uvnitř system.measure)
y_traj_flat = system.measure(x_traj_flat) # [T, 3]

# Nahrazení barometru reálnými daty (pokud je to žádoucí)
seq_len = x_traj_flat.shape[0]
# Pokud chceš simulovat čistě syntetický šum barometru, tento řádek
↳ zakomentuj:
y_traj_flat[:, 0] = real_hB_tensor[:seq_len]

x_ref = x_traj_flat.unsqueeze(0) # [1, T, 4]
y_ref = y_traj_flat.unsqueeze(0) # [1, T, 3]

return x_ref, y_ref

# --- KONFIGURACE MC ---
MC_ITERATIONS = 20 # Nastav rozumné číslo (pro 100 grafů by to zahrtilo
↳ notebook)
PLOT_PER_ITERATION = True # Zda vykreslovat grafy pro každý běh

print(f"=== SPUŠTĚNÍ MONTE CARLO SIMULACE ({MC_ITERATIONS} běhů) ===")
print("Modely: KalmanNet vs. UKF vs. PF")

# 1. Příprava Ground Truth (GT)
real_traj_tensor = torch.from_numpy(real_traj_np).float().to(device)
# Získáme GT stavy (X) jen jednou, protože trajektorie je fixní
# Měření (Y) se bude měnit v každé iteraci kvůli šumu
x_ref_tensor_static, _ = get_reference_test_set(system_model, real_traj_tensor)
x_gt = x_ref_tensor_static.squeeze().cpu().numpy()
seq_len = x_gt.shape[0]

# 2. Inicializace pro sběr dat
detailed_results = [] # Seznam slovníků pro DataFrame
agg_mse = {"KNet": [], "UKF": [], "PF": []}
agg_pos = {"KNet": [], "UKF": [], "PF": []}

```

```

# Ujistíme se, že KNet je v eval módu
state_knet2.eval()

# --- HLAVNÍ SMYČKA ---
for i in tqdm(range(MC_ITERATIONS), desc="Simulace"):

    # A) Generování nového měření (s novým náhodným šumem)
    # Voláme funkci znovu, abychom dostali Y s jinou realizací šumu (pokud
    ↪ system.measure šumí)
    _, y_ref_tensor = get_reference_test_set(system_model, real_traj_tensor)

    # B) Inference: KalmanNet
    with torch.no_grad():
        initial_state = x_ref_tensor_static[:, 0, :] # [1, 4]
        state_knet2.reset(batch_size=1, initial_state=initial_state)

        knet_preds = []
        y_input = y_ref_tensor

        for t in range(1, seq_len):
            y_t = y_input[:, t, :]
            x_est = state_knet2.step(y_t)
            knet_preds.append(x_est)

        knet_preds_tensor = torch.stack(knet_preds, dim=1)
        full_knet_est = torch.cat([initial_state.unsqueeze(1),
    ↪ knet_preds_tensor], dim=1)
        x_est_knet = full_knet_est.squeeze().cpu().numpy()

    # C) Inference: UKF & PF
    y_for_filters = y_ref_tensor.squeeze(0)

    # !!! KLÍČOVÁ OPRAVA: Použijeme SKUTEČNÝ startovní bod trajektorie !!!
    true_init_state = x_ref_tensor_static[0, 0, :]

    # UKF
    ukf_ideal = Filters.UnscentedKalmanFilter(system_model)
    ukf_res = ukf_ideal.process_sequence(
        y_seq=y_for_filters,
        Ex0=true_init_state, # Správný start
        P0=system_model.P0
    )
    x_est_ukf = ukf_res['x_filtered'].cpu().numpy()

    # PF

```



```

    pf = Filters.ParticleFilter(system_model, num_particles=10000) # Počet
↪částeč dle výkonu
    pf_res = pf.process_sequence(
        y_seq=y_for_filters,
        Ex0=true_init_state, # Správný start
        P0=system_model.P0
    )
    x_est_pf = pf_res['x_filtered'].cpu().numpy()

# D) Výpočet chyb pro tento běh
# KNet
diff_knet = x_est_knet - x_gt
mse_knet = np.mean(diff_knet**2)
pos_err_knet = np.mean(np.sqrt(diff_knet[:, 0]**2 + diff_knet[:, 1]**2))

# UKF
diff_ukf = x_est_ukf - x_gt
mse_ukf = np.mean(diff_ukf**2)
pos_err_ukf = np.mean(np.sqrt(diff_ukf[:, 0]**2 + diff_ukf[:, 1]**2))

# PF
diff_pf = x_est_pf - x_gt
mse_pf = np.mean(diff_pf**2)
pos_err_pf = np.mean(np.sqrt(diff_pf[:, 0]**2 + diff_pf[:, 1]**2))

# Uložení do agregátoru
agg_mse["KNet"].append(mse_knet)
agg_pos["KNet"].append(pos_err_knet)
agg_mse["UKF"].append(mse_ukf)
agg_pos["UKF"].append(pos_err_ukf)
agg_mse["PF"].append(mse_pf)
agg_pos["PF"].append(pos_err_pf)

# Uložení do detailního seznamu
detailed_results.append({
    "Run_ID": i + 1,
    "KNet_MSE": mse_knet,
    "UKF_MSE": mse_ukf,
    "PF_MSE": mse_pf,
    "KNet_PosErr": pos_err_knet,
    "UKF_PosErr": pos_err_ukf,
    "PF_PosErr": pos_err_pf
})

# E) Vykreslení grafu pro TENTO běh
if PLOT_PER_ITERATION:

```

```

fig = plt.figure(figsize=(12, 6))
plt.plot(x_gt[:, 0], x_gt[:, 1], 'k-', linewidth=3, alpha=0.3,
↳label='Ground Truth')

plt.plot(x_est_knet[:, 0], x_est_knet[:, 1], 'g-', linewidth=1.5,
↳label=f'KalmanNet (MSE: {mse_knet:.1f})')
plt.plot(x_est_ukf[:, 0], x_est_ukf[:, 1], 'b--', linewidth=1,
↳label=f'UKF (MSE: {mse_ukf:.1f})')
plt.plot(x_est_pf[:, 0], x_est_pf[:, 1], 'r:', linewidth=1, alpha=0.8,
↳label=f'PF (MSE: {mse_pf:.1f})')

plt.title(f"Run {i+1}/{MC_ITERATIONS}: Trajectory Comparison")
plt.xlabel("X [m]")
plt.ylabel("Y [m]")
plt.legend()
plt.axis('equal')
plt.grid(True)
plt.show()

# --- VÝPIS VÝSLEDKŮ ---

# 1. Detailní tabulka všech běhů
df_results = pd.DataFrame(detailed_results)
print("\n" + "="*80)
print(f"DETAILNÍ VÝSLEDKY PO JEDNOTLIVÝCH BĚZÍCH")
print("="*80)
# Formátování tabulky pro hezčí výpis
pd.options.display.float_format = '{:,.2f}'.format
print(df_results[["Run_ID", "KNet_MSE", "UKF_MSE", "PF_MSE", "KNet_PosErr",
↳"UKF_PosErr", "PF_PosErr"]])

# 2. Souhrnná statistika
print("\n" + "="*80)
print(f"SOUHRNNÁ STATISTIKA ({MC_ITERATIONS} běhů)")
print("="*80)

def get_stats(key):
    return np.mean(agg_mse[key]), np.std(agg_mse[key]), np.mean(agg_pos[key]),
↳np.std(agg_pos[key])

knet_stats = get_stats("KNet")
ukf_stats = get_stats("UKF")
pf_stats = get_stats("PF")

print(f"{'Model':<15} | {'MSE (Mean ± Std)':<25} | {'Pos Error (Mean ± Std)':
↳<25}")

```

```

print("-" * 75)
print(f"{'KalmanNet':<15} | {knet_stats[0]:.1f} ± {knet_stats[1]:.1f} |_
↳ {knet_stats[2]:.2f} ± {knet_stats[3]:.2f} m")
print(f"{'UKF':<15} | {ukf_stats[0]:.1f} ± {ukf_stats[1]:.1f} | {ukf_stats[2]:.
↳ 2f} ± {ukf_stats[3]:.2f} m")
print(f"{'PF':<15} | {pf_stats[0]:.1f} ± {pf_stats[1]:.1f} | {pf_stats[2]:.2f}_
↳ ± {pf_stats[3]:.2f} m")
print("="*80)

# 3. Finální Boxplot
plt.figure(figsize=(10, 6))
plt.boxplot([agg_pos["KNet"], agg_pos["UKF"], agg_pos["PF"]],_
↳ labels=['KalmanNet', 'UKF', 'PF'], patch_artist=True)
plt.title(f"Position Error Distribution ({MC_ITERATIONS} runs)")
plt.ylabel("Avg Position Error [m]")
plt.grid(True, axis='y')
plt.show()

```


=== SPUŠTĚNÍ MONTE CARLO SIMULACE (20 běhů) ===

Modely: KalmanNet vs. UKF vs. PF

Simulace: 0% | 0/20 [00:00<?, ?it/s]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.


Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 5% | 1/20 [00:18<05:50, 18.47s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.


Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



| 2/20 [00:37<05:37, 18.72s/it]


[illegible]

[illegible]




Simulace: 15% | 3/20 [00:53<04:59, 17.61s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 20% | 4/20 [01:11<04:45, 17.82s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



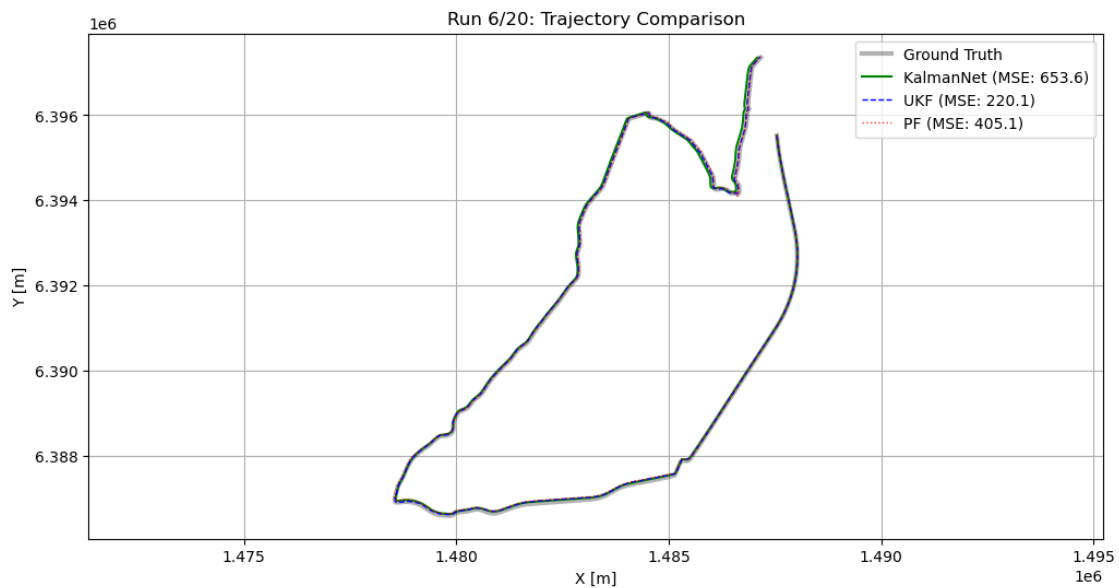
Simulace: 25% | 5/20 [01:29<04:29, 17.94s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.




Simulace: 30% | 6/20 [01:47<04:11, 17.96s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

28

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.




Simulace: 40% | 8/20 [02:23<03:34, 17.85s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

[illegible]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 45% | 9/20 [02:42<03:19, 18.11s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

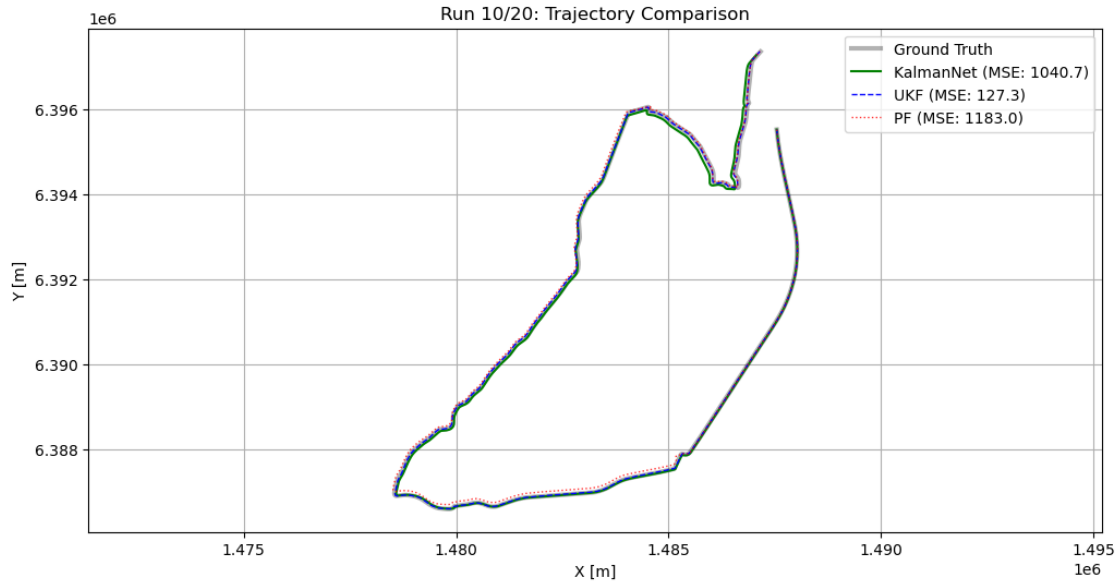
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.


Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 50% | 10/20 [03:00<03:02, 18.22s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.


Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 55% | 11/20 [03:20<02:47, 18.66s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 60% | 12/20 [03:36<02:23, 18.00s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.


Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



[illegible]

[illegible]

[illegible]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.




Simulace: 80% | 16/20 [04:45<01:09, 17.45s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

[illegible]


Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 85% | 17/20 [05:02<00:51, 17.12s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
 Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

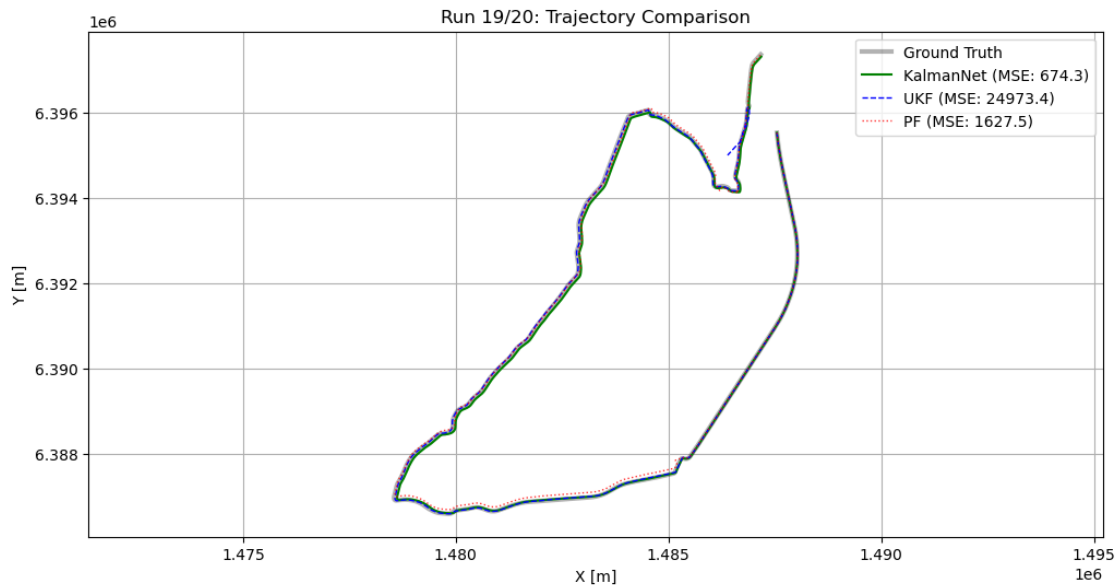
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 90% | 18/20 [05:20<00:35, 17.59s/it]


Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 95% | 19/20 [05:39<00:17, 17.72s/it]

Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.
Varování: Součet vah je téměř nulový. Resetuji na uniformní rozdělení.



Simulace: 100% | 20/20 [05:56<00:00, 17.84s/it]

DETAILNÍ VÝSLEDKY PO JEDNOTLIVÝCH BĚŽÍCH

	Run_ID	KNet_MSE	UKF_MSE	PF_MSE	KNet_PosErr	UKF_PosErr	PF_PosErr
0	1	415.10	97.64	12,822.48	32.32	17.85	126.83
1	2	656.47	157.95	1,108.11	44.00	22.11	54.43
2	3	427.84	99.91	545,751.62	37.02	17.45	530.20
3	4	747.72	81.96	240.19	49.84	16.66	27.67
4	5	569.32	96.31	122.76	39.11	17.06	17.74
5	6	653.62	220.10	405.13	45.25	26.51	35.33
6	7	508.27	126.00	3,113.43	40.08	19.96	97.22
7	8	604.05	552.56	4,515.20	44.02	31.33	115.07
8	9	977.39	422,025.69	559,067.25	52.13	418.73	526.19
9	10	1,040.68	127.31	1,183.00	54.03	19.64	60.07
10	11	492.55	97.31	115.96	38.04	16.95	18.45
11	12	694.31	421,548.50	90.70	42.17	417.65	16.46
12	13	283.74	132.99	174.09	30.23	20.60	22.89
13	14	2,364.01	425,577.53	788.31	74.99	425.11	43.85
14	15	442.22	84.37	552,143.12	37.15	15.63	494.36
15	16	820.06	25,922.73	2,704.09	50.71	80.33	90.01
16	17	423.52	98.84	525,642.81	37.41	17.51	524.50
17	18	1,059.68	126.29	138.99	53.40	18.11	19.03
18	19	674.29	24,973.37	1,627.52	47.02	74.43	69.84
19	20	963.69	319,948.88	1,595.29	50.94	375.32	64.14

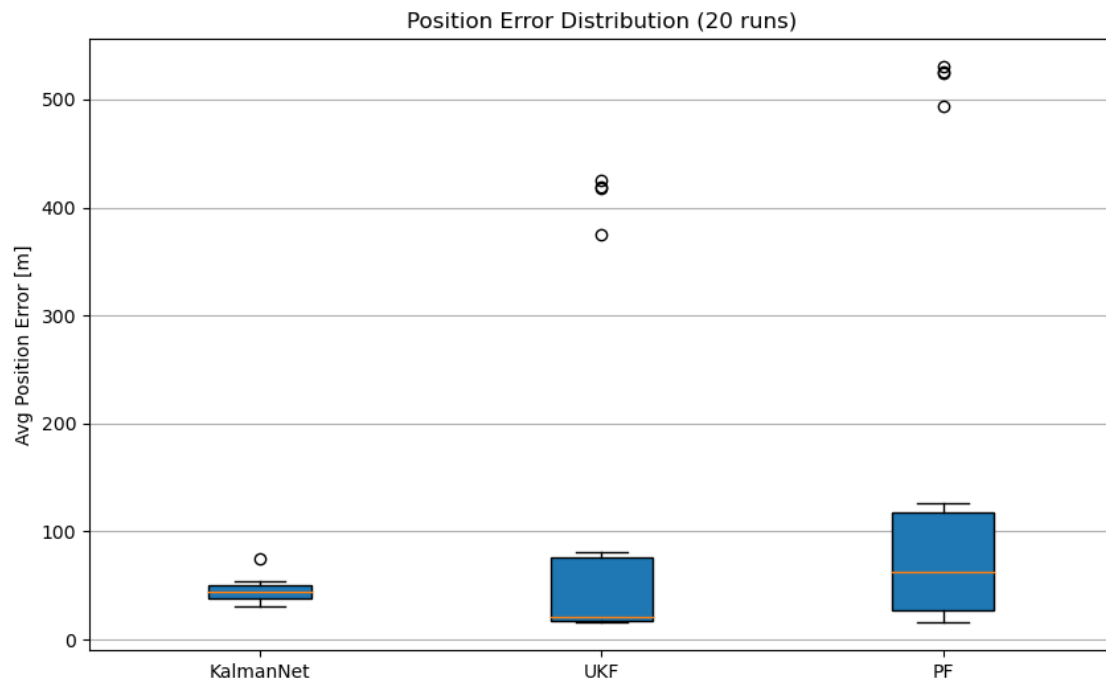
=====

SOUHRNNÁ STATISTIKA (20 běhů)

=====

Model	MSE (Mean ± Std)	Pos Error (Mean ± Std)
KalmanNet	740.9 ± 431.6	44.99 ± 9.69 m
UKF	82104.8 ± 159022.7	103.45 ± 154.12 m
PF	110667.5 ± 217580.8	147.71 ± 188.32 m

=====



2 Test na syntetické trajektorii

```
[ ]: import torch
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd # Pro hezkou tabulku
import Filters
from tqdm import tqdm
real_traj_np = souradniceGNSS[:, 2, :].T

real_traj_tensor = torch.from_numpy(real_traj_np).float().to(device)
train_source_tensor = real_traj_tensor[:, :]
```

```

# --- POMOCNÁ FUNKCE PRO GENEROVÁNÍ DAT ---
def get_reference_test_set(system, real_traj_tensor, reverse=False):
    # Oříznutí trajektorie (pokud je potřeba)
    # real_traj_tensor = real_traj_tensor[:1050,:]

    device = system.Ex0.device

    # Předpoklad: mat_data je globální proměnná s načteným .mat souborem
    # hB_np = mat_data['hB']
    # real_hB_tensor = torch.from_numpy(hB_np).float().to(device).view(-1)

    pos_full = real_traj_tensor.clone().to(device)

    deltas = pos_full[1:] - pos_full[:-1]
    last_vel = deltas[-1:]
    velocities = torch.cat([deltas, last_vel], dim=0) # [T, 2]

    x_traj_flat = torch.cat([pos_full, velocities], dim=1) # [T, 4]

    # Generování měření (s náhodným šumem uvnitř system.measure)
    y_traj_flat = system.measure(x_traj_flat) # [T, 3]

    # Nahrazení barometru reálnými daty (pokud je to žádoucí)
    seq_len = x_traj_flat.shape[0]
    # Pokud chceš simulovat čistě syntetický šum barometru, tento řádek
    ↪zakomentuj:
    # y_traj_flat[:, 0] = real_hB_tensor[:seq_len]

    x_ref = x_traj_flat.unsqueeze(0) # [1, T, 4]
    y_ref = y_traj_flat.unsqueeze(0) # [1, T, 3]

    return x_ref, y_ref

# --- KONFIGURACE MC ---
MC_ITERATIONS = 10 # Nastav rozumné číslo (pro 100 grafů by to zahrtilo
    ↪notebook)
PLOT_PER_ITERATION = True # Zda vykreslovat grafy pro každý běh

print(f"=== SPUŠTĚNÍ MONTE CARLO SIMULACE ({MC_ITERATIONS} běhů) ===")
print("Modely: KalmanNet vs. UKF vs. PF")

# 1. Příprava Ground Truth (GT)
real_traj_tensor = torch.from_numpy(real_traj_np).float().to(device)
# Získáme GT stavy (X) jen jednou, protože trajektorie je fixní
# Měření (Y) se bude měnit v každé iteraci kvůli šumu
x_ref_tensor_static, _ = get_reference_test_set(system_model, real_traj_tensor)

```

```

x_gt = x_ref_tensor_static.squeeze().cpu().numpy()
seq_len = x_gt.shape[0]

# 2. Inicializace pro sběr dat
detailed_results = [] # Seznam slovníků pro DataFrame
agg_mse = {"KNet": [], "UKF": [], "PF": []}
agg_pos = {"KNet": [], "UKF": [], "PF": []}

# Ujistíme se, že KNet je v eval módu
state_knet2.eval()

# --- HLAVNÍ SMYČKA ---
for i in tqdm(range(MC_ITERATIONS), desc="Simulace"):

    # A) Generování nového měření (s novým náhodným šumem)
    # Voláme funkci znovu, abychom dostali Y s jinou realizací šumu (pokud
    ↪system.measure šumí)
    _, y_ref_tensor = get_reference_test_set(system_model, real_traj_tensor)

    # B) Inference: KalmanNet
    with torch.no_grad():
        initial_state = x_ref_tensor_static[:, 0, :] # [1, 4]
        state_knet2.reset(batch_size=1, initial_state=initial_state)

        knet_preds = []
        y_input = y_ref_tensor

        for t in range(1, seq_len):
            y_t = y_input[:, t, :]
            x_est = state_knet2.step(y_t)
            knet_preds.append(x_est)

        knet_preds_tensor = torch.stack(knet_preds, dim=1)
        full_knet_est = torch.cat([initial_state.unsqueeze(1),
        ↪knet_preds_tensor], dim=1)
        x_est_knet = full_knet_est.squeeze().cpu().numpy()

    # C) Inference: UKF & PF
    y_for_filters = y_ref_tensor.squeeze(0)

    # !!! KLÍČOVÁ OPRAVA: Použijeme SKUTEČNÝ startovní bod trajektorie !!!
    true_init_state = x_ref_tensor_static[0, 0, :]

    # UKF
    ukf_ideal = Filters.UnscentedKalmanFilter(system_model)
    ukf_res = ukf_ideal.process_sequence(
        y_seq=y_for_filters,

```

```

        Ex0=true_init_state, # Správný start
        P0=system_model.P0
    )
    x_est_ukf = ukf_res['x_filtered'].cpu().numpy()

    # PF
    pf = Filters.ParticleFilter(system_model, num_particles=10000) # Počet
↪ částic dle výkonu
    pf_res = pf.process_sequence(
        y_seq=y_for_filters,
        Ex0=true_init_state, # Správný start
        P0=system_model.P0
    )
    x_est_pf = pf_res['x_filtered'].cpu().numpy()

    # D) Výpočet chyb pro tento běh
    # KNet
    diff_knet = x_est_knet - x_gt
    mse_knet = np.mean(diff_knet**2)
    pos_err_knet = np.mean(np.sqrt(diff_knet[:, 0]**2 + diff_knet[:, 1]**2))

    # UKF
    diff_ukf = x_est_ukf - x_gt
    mse_ukf = np.mean(diff_ukf**2)
    pos_err_ukf = np.mean(np.sqrt(diff_ukf[:, 0]**2 + diff_ukf[:, 1]**2))

    # PF
    diff_pf = x_est_pf - x_gt
    mse_pf = np.mean(diff_pf**2)
    pos_err_pf = np.mean(np.sqrt(diff_pf[:, 0]**2 + diff_pf[:, 1]**2))

    # Uložení do agregátoru
    agg_mse["KNet"].append(mse_knet)
    agg_pos["KNet"].append(pos_err_knet)
    agg_mse["UKF"].append(mse_ukf)
    agg_pos["UKF"].append(pos_err_ukf)
    agg_mse["PF"].append(mse_pf)
    agg_pos["PF"].append(pos_err_pf)

    # Uložení do detailního seznamu
    detailed_results.append({
        "Run_ID": i + 1,
        "KNet_MSE": mse_knet,
        "UKF_MSE": mse_ukf,
        "PF_MSE": mse_pf,
        "KNet_PosErr": pos_err_knet,

```

```

        "UKF_PosErr": pos_err_ukf,
        "PF_PosErr": pos_err_pf
    })

    # E) Vykreslení grafu pro TENTO běh
    if PLOT_PER_ITERATION:
        fig = plt.figure(figsize=(12, 6))
        plt.plot(x_gt[:, 0], x_gt[:, 1], 'k-', linewidth=3, alpha=0.3,
        ↪label='Ground Truth')

        plt.plot(x_est_knet[:, 0], x_est_knet[:, 1], 'g-', linewidth=1.5,
        ↪label=f'KalmanNet (MSE: {mse_knet:.1f})')
        plt.plot(x_est_ukf[:, 0], x_est_ukf[:, 1], 'b--', linewidth=1,
        ↪label=f'UKF (MSE: {mse_ukf:.1f})')
        plt.plot(x_est_pf[:, 0], x_est_pf[:, 1], 'r:', linewidth=1, alpha=0.8,
        ↪label=f'PF (MSE: {mse_pf:.1f})')

        plt.title(f"Run {i+1}/{MC_ITERATIONS}: Trajectory Comparison")
        plt.xlabel("X [m]")
        plt.ylabel("Y [m]")
        plt.legend()
        plt.axis('equal')
        plt.grid(True)
        plt.show()

# --- VÝPIS VÝSLEDKŮ ---

# 1. Detailní tabulka všech běhů
df_results = pd.DataFrame(detailed_results)
print("\n" + "="*80)
print(f"DETAILNÍ VÝSLEDKY PO JEDNOTLIVÝCH BĚŽÍCH")
print("="*80)
# Formátování tabulky pro hezčí výpis
pd.options.display.float_format = '{:,.2f}'.format
print(df_results[["Run_ID", "KNet_MSE", "UKF_MSE", "PF_MSE", "KNet_PosErr",
↪"UKF_PosErr", "PF_PosErr"]])

# 2. Souhrnná statistika
print("\n" + "="*80)
print(f"SOUHRNNÁ STATISTIKA ({MC_ITERATIONS} běhů)")
print("="*80)

def get_stats(key):
    return np.mean(agg_mse[key]), np.std(agg_mse[key]), np.mean(agg_pos[key]),
    ↪np.std(agg_pos[key])

```

```

knet_stats = get_stats("KNet")
ukf_stats = get_stats("UKF")
pf_stats = get_stats("PF")

print(f"{'Model':<15} | {'MSE (Mean ± Std)':<25} | {'Pos Error (Mean ± Std)':<25}")
print("-" * 75)
print(f"{'KalmanNet':<15} | {knet_stats[0]:.1f} ± {knet_stats[1]:.1f} | {knet_stats[2]:.2f} ± {knet_stats[3]:.2f} m")
print(f"{'UKF':<15} | {ukf_stats[0]:.1f} ± {ukf_stats[1]:.1f} | {ukf_stats[2]:.2f} ± {ukf_stats[3]:.2f} m")
print(f"{'PF':<15} | {pf_stats[0]:.1f} ± {pf_stats[1]:.1f} | {pf_stats[2]:.2f} ± {pf_stats[3]:.2f} m")
print("="*80)

# 3. Finální Boxplot
plt.figure(figsize=(10, 6))
plt.boxplot([agg_pos["KNet"], agg_pos["UKF"], agg_pos["PF"]], labels=['KalmanNet', 'UKF', 'PF'], patch_artist=True)
plt.title(f"Position Error Distribution ({MC_ITERATIONS} runs)")
plt.ylabel("Avg Position Error [m]")
plt.grid(True, axis='y')
plt.show()

```